

Alunos: Alexis Mariz, Leandro Diniz e Samuel Lipovetsky.

Introdução

Essa fase do projeto foi realizada pelo ChatGPT. Segue o link:
(<https://chatgpt.com/share/679931f9-de30-800a-83f9-2f752a780b3a>)

1. Business Understanding

Contexto

O conjunto de dados foca em métricas globais de saúde e indicadores socioeconômicos, com o objetivo de abordar disparidades na expectativa de vida entre países e ao longo do tempo. O público-alvo inclui formuladores de políticas, organizações de saúde e economistas que buscam identificar os principais fatores que influenciam a expectativa de vida e implementar medidas para melhorar os resultados de saúde pública.

Problema de Negócio

Compreender os fatores que influenciam a expectativa de vida é crucial para moldar políticas de saúde, alocar recursos e melhorar o bem-estar da população. Esse problema é particularmente relevante em países em desenvolvimento, onde lidar com taxas de mortalidade, prevalência de doenças e desafios socioeconômicos pode melhorar drasticamente a qualidade de vida.

Objetivos

- **Aumentar a expectativa de vida:** Identificar e abordar fatores que impactam negativamente a saúde.
- **Otimizar os gastos com saúde:** Focar recursos nas áreas de maior impacto.
- **Monitorar o progresso:** Acompanhar o sucesso de iniciativas de saúde em diferentes regiões e anos.
- **Promover equidade:** Reduzir as disparidades na expectativa de vida entre países desenvolvidos e em desenvolvimento.

Métricas de Sucesso

- Aumentos mensuráveis na expectativa de vida nas regiões-alvo.
 - Redução nas taxas de mortalidade de grupos etários específicos.
 - Maior eficiência na alocação de recursos (ex.: gastos com imunização ou educação).
-

Objetivo do Conjunto de Dados

Finalidade

O conjunto de dados fornece informações abrangentes de saúde e socioeconômicas para analisar e prever tendências globais de expectativa de vida. Ele serve como base para entender correlações entre fatores como PIB, acesso à saúde e prevalência de doenças com a expectativa de vida.

Casos de Uso

- **Recomendações de Políticas:** Identificar fatores críticos de saúde para priorizar intervenções, como aumentar as taxas de imunização ou reduzir a desnutrição.
 - **Modelagem Preditiva:** Usar tendências históricas para prever a expectativa de vida em diferentes cenários (ex.: aumento nos gastos com saúde).
 - **Benchmarking:** Comparar países ou regiões para identificar boas práticas.
 - **Campanhas de Conscientização:** Fornecer insights baseados em dados para campanhas de saúde pública direcionadas a problemas específicos, como mortalidade infantil ou HIV/AIDS.
-

Fonte dos Dados

Detalhes

- **Origem:** Provavelmente obtidos de bancos de dados globais de saúde, como OMS, Banco Mundial ou instituições similares.
 - **Método:** Coletados de relatórios nacionais de saúde, censos e pesquisas, integrando dados demográficos e de saúde.
 - **Considerações Éticas:** Dados agregados sem informações pessoais identificáveis, tornando-os adequados para análise. No entanto, disparidades nos padrões de relato entre países podem introduzir viés.
-

Características do Conjunto de Dados

Estrutura

- **Linhas:** 2.938 (representando observações por país e ano).
- **Colunas:** 22, incluindo variáveis numéricas (ex.: PIB, taxas de mortalidade) e categóricas (ex.: país, status de desenvolvimento).

Principais Recursos

- **País, Ano e Status:** Identificam o contexto geográfico e temporal.
- **Expectativa de Vida:** Variável-alvo da análise.
- **Indicadores de Saúde:** Métricas como mortalidade infantil, IMC, prevalência de HIV/AIDS e taxas de imunização.

- **Métricas Econômicas:** PIB e despesas totais com saúde destacam fatores socioeconômicos.
- **Indicadores Educacionais:** "Escolaridade" e "Composição de renda dos recursos" refletem o desenvolvimento e sua correlação com os resultados de saúde.

Problemas nos Dados

- Valores ausentes em colunas críticas (ex.: Hepatite B, PIB) requerem estratégias de imputação ou exclusão.
 - Outliers nas distribuições de PIB e população podem precisar de ajustes.
 - Engenharia de recursos, como normalização de métricas de despesas, pode melhorar o desempenho dos modelos.
-

Relação com o Problema de Negócio

Conexões

- **Expectativa de Vida (Alvo):** Central para entender tendências de saúde pública.
- **Taxas de Mortalidade:** Alta correlação com a expectativa de vida; reduzi-las é um objetivo político.
- **Taxas de Imunização:** Indicam áreas que necessitam de intervenções de saúde.
- **Indicadores Econômicos:** PIB e despesas orientam a alocação de recursos.
- **Níveis Educacionais:** Ligados à conscientização e prevenção de doenças.

Adequação

A combinação de métricas de saúde, econômicas e educacionais no conjunto de dados está diretamente alinhada ao objetivo de melhorar a expectativa de vida por meio de intervenções direcionadas.

Limitações

- **Lacunas nos Dados:** Valores ausentes em métricas de saúde podem reduzir a precisão.
- **Viés Regional:** Diferenças na qualidade dos dados entre países desenvolvidos e em desenvolvimento.
- **Pressupostos:** Baseia-se em dados históricos, que podem não refletir completamente mudanças recentes em políticas de saúde ou condições econômicas. ``

2. Data Understanding & Data Preparation

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt

# Load the dataset
data = pd.read_csv('dataset/Life Expectancy Data.csv')
```

```

# Initial Exploration
# Basic info
data_info = data.info()

# Descriptive statistics
data_description = data.describe(include='all')

# Check for missing values
missing_values = data.isnull().sum()

# Check for duplicates
duplicates = data.duplicated().sum()

# Visualizations for numeric columns
numeric_cols =
data.select_dtypes(include=[np.number]).columns.tolist()

# Histograms for numeric columns
for col in numeric_cols:
    plt.figure(figsize=(10, 5))
    sns.histplot(data[col], kde=True, bins=30)
    plt.title(f'Distribution of {col}')
    plt.show()

# Heatmap for correlations
plt.figure(figsize=(12, 8))
sns.heatmap(data[numeric_cols].corr(), annot=True, cmap='coolwarm',
fmt=".2f")
plt.title('Correlation Heatmap of Numerical Features')
plt.show()

# Summary of findings
summary = {
    "Missing Values": missing_values,
    "Duplicates": duplicates,
    "Descriptive Stats": data_description
}

import ace_tools as tools;
tools.display_dataframe_to_user(name="Initial Findings Summary",
dataframe=pd.DataFrame(summary))

# Display pairplot for relationships (limited to a few columns for
clarity)
selected_columns = ['Life expectancy ', 'Adult Mortality', 'BMI',
'HIV/AIDS', 'GDP', 'Schooling']
sns.pairplot(data[selected_columns].dropna())
plt.show()

```

summary

<class 'pandas.core.frame.DataFrame'>



RangeIndex: 2938 entries, 0 to 2937

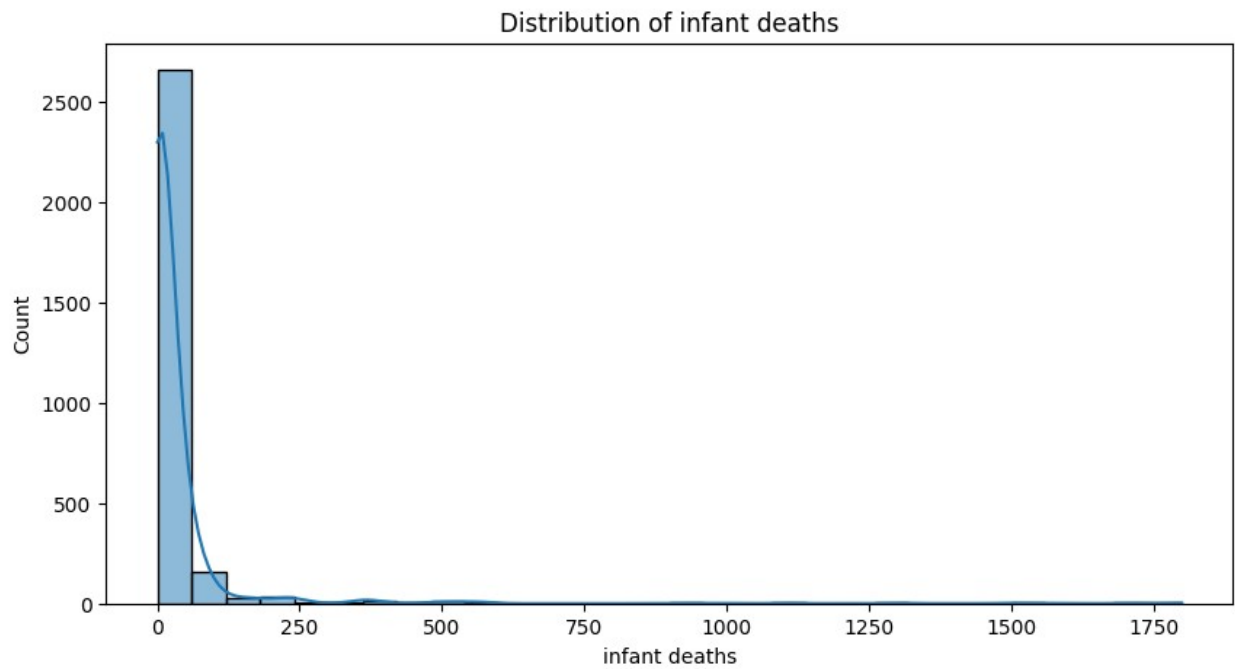
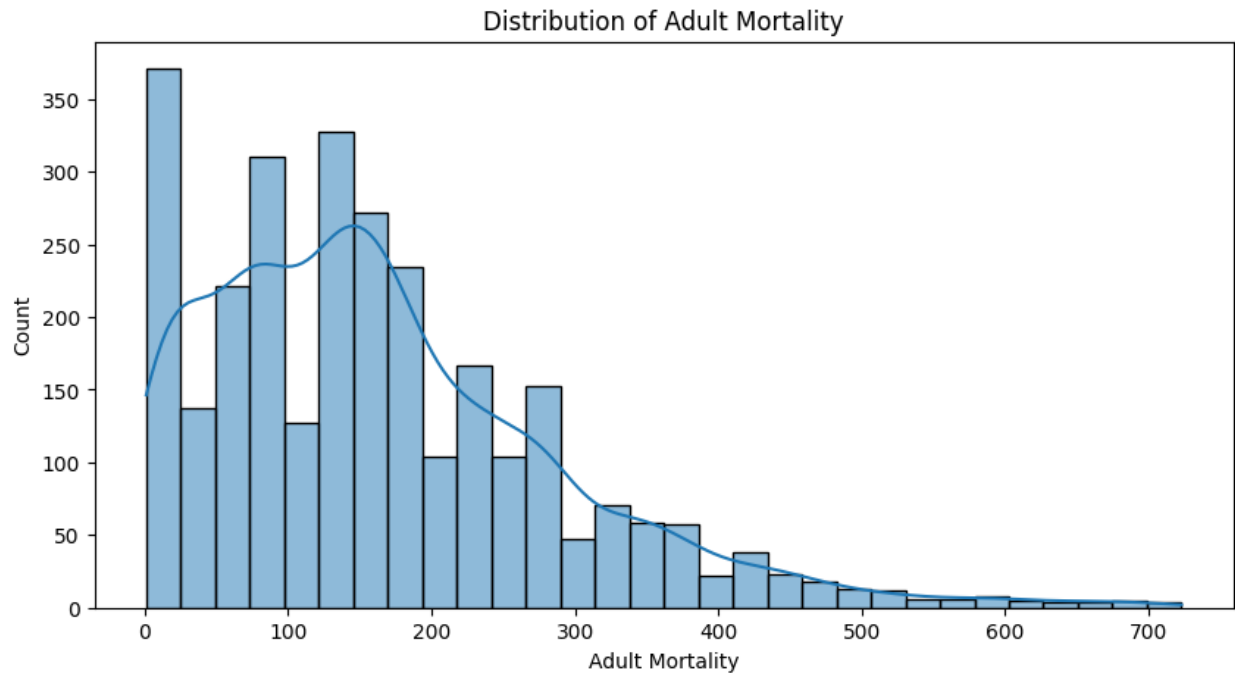
Data columns (total 22 columns):



#	Column	Non-Null Count	Dtype
0	Country	2938 non-null	object
1	Year	2938 non-null	int64
2	Status	2938 non-null	object
3	Life expectancy	2928 non-null	float64
4	Adult Mortality	2928 non-null	float64
5	infant deaths	2938 non-null	int64
6	Alcohol	2744 non-null	float64
7	percentage expenditure	2938 non-null	float64
8	Hepatitis B	2385 non-null	float64
9	Measles	2938 non-null	int64
10	BMI	2904 non-null	float64
11	under-five deaths	2938 non-null	int64
12	Polio	2919 non-null	float64
13	Total expenditure	2712 non-null	float64
14	Diphtheria	2919 non-null	float64
15	HIV/AIDS	2938 non-null	float64
16	GDP	2490 non-null	float64
17	Population	2286 non-null	float64
18	thinness 1-19 years	2904 non-null	float64
19	thinness 5-9 years	2904 non-null	float64
20	Income composition of resources	2771 non-null	float64
21	Schooling	2775 non-null	float64


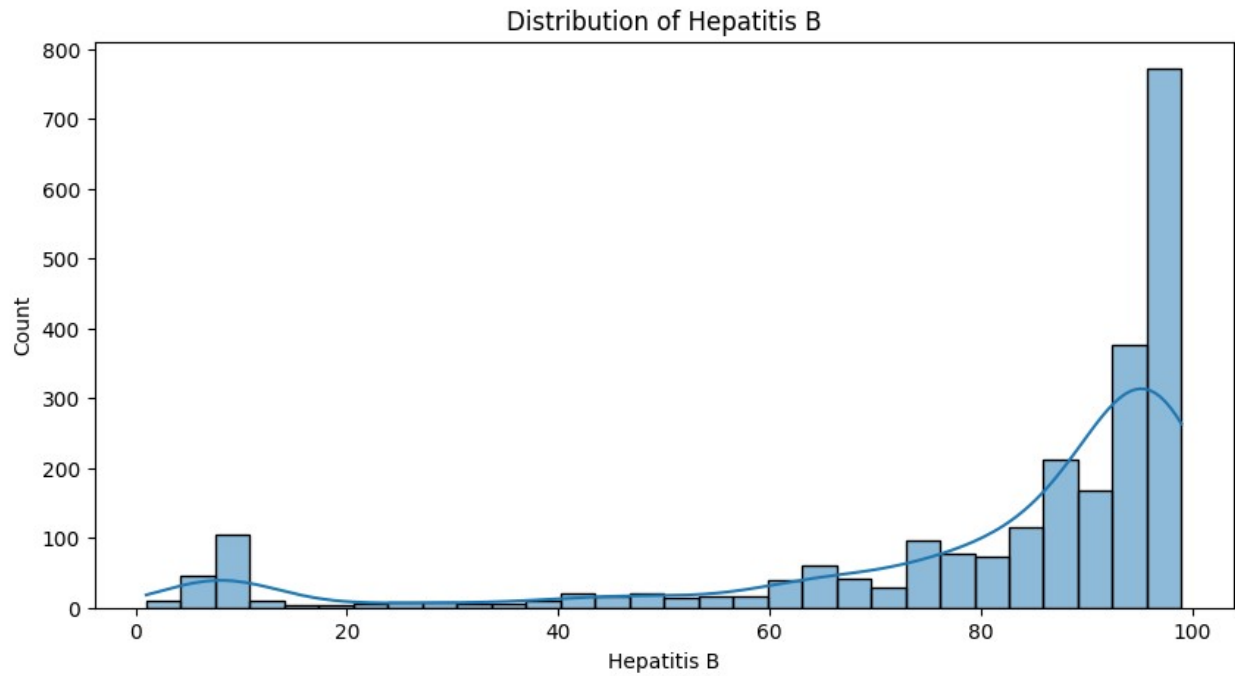
dtypes: float64(16), int64(4), object(2)



memory usage: 505.1+ KB












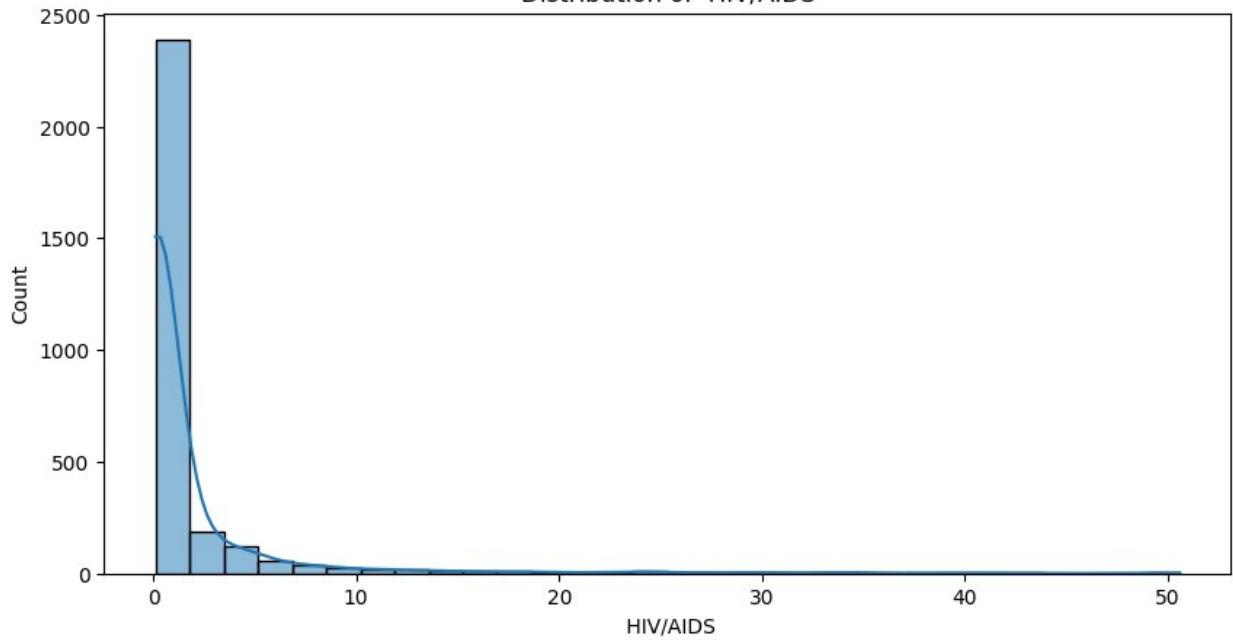






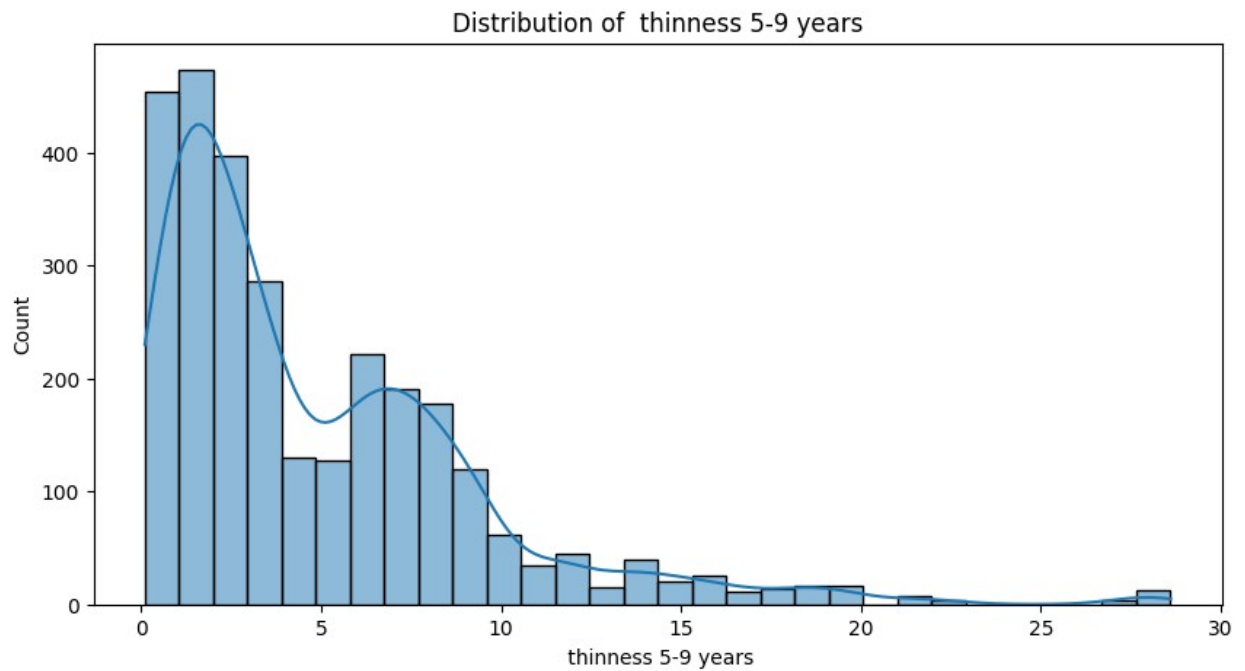

Distribution of Diphtheria






Distribution of HIV/AIDS











```
-----
-----
ModuleNotFoundError                                Traceback (most recent call
last)
Cell In[1], line 45
    38 # Summary of findings
    39 summary = {
    40     "Missing Values": missing_values,
    41     "Duplicates": duplicates,
    42     "Descriptive Stats": data_description
    43 }
--> 45 import ace_tools as tools;
tools.display_dataframe_to_user(name="Initial Findings Summary",
dataframe=pd.DataFrame(summary))
    47 # Display pairplot for relationships (limited to a few columns
for clarity)
    48 selected_columns = ['Life expectancy ', 'Adult Mortality',
'BMI', 'HIV/AIDS', 'GDP', 'Schooling']
```


ModuleNotFoundError: No module named 'ace_tools'

O módulo "ace_tools" é um módulo interno do ChatGPT, por isso o erro quando tentamos executar fora do seu ambiente. Pedi ao ChatGPT que refizesse o código sem utilizar esse módulo: <https://chatgpt.com/share/679958ce-923c-800a-9003-2ee9cf8c4239>

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt

# Carregando o dataset
data = pd.read_csv('dataset/Life Expectancy Data.csv')

# 1. Exploração Inicial

# Informações básicas (schema, tipos e contagem de linhas)
data.info()

# Estatísticas descritivas
data_description = data.describe(include='all')

# Verificando valores ausentes
missing_values = data.isnull().sum()

# Verificando duplicatas
duplicates = data.duplicated().sum()

# 2. Visualizações de colunas numéricas
numeric_cols =
data.select_dtypes(include=[np.number]).columns.tolist()

# Histograma de cada coluna numérica
for col in numeric_cols:
    plt.figure(figsize=(10, 5))
    sns.histplot(data[col], kde=True, bins=30)
    plt.title(f'Distribution of {col}')
    plt.show()

# Heatmap de correlação
plt.figure(figsize=(12, 8))
sns.heatmap(data[numeric_cols].corr(), annot=True, cmap='coolwarm',
fmt=".2f")
plt.title('Correlation Heatmap of Numerical Features')
plt.show()

# 3. Sumário de resultados
print("\n===== Sumário de Resultados =====")
print("\nValores Ausentes:")
```

```

print(missing_values)
print("\nQuantidade de Duplicatas:")
print(duplicates)
print("\nEstatísticas Descritivas:")
print(data_description)

# 4. Pairplot para algumas colunas selecionadas
selected_columns = ['Life expectancy ', 'Adult Mortality', 'BMI',
'HIV/AIDS', 'GDP', 'Schooling']
sns.pairplot(data[selected_columns].dropna())
plt.show()

```

```
<class 'pandas.core.frame.DataFrame'>
```


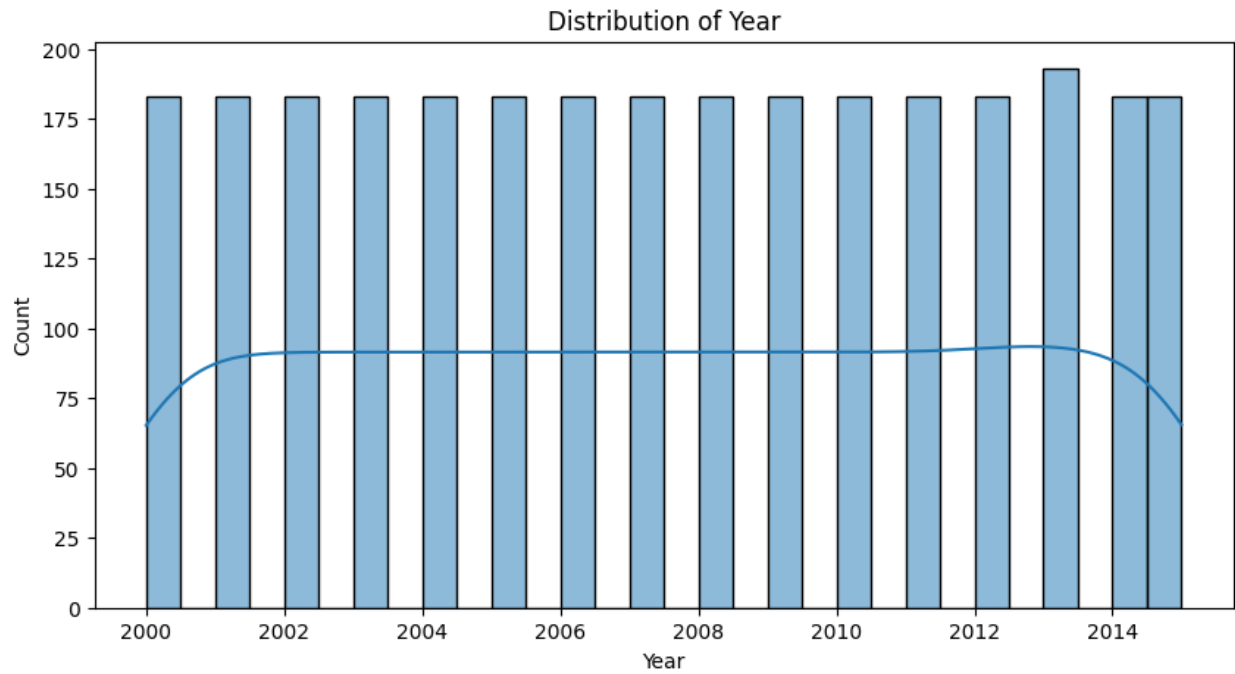
```
RangeIndex: 2938 entries, 0 to 2937
```

```
Data columns (total 22 columns):
```


#	Column	Non-Null Count	Dtype
0	Country	2938 non-null	object
1	Year	2938 non-null	int64
2	Status	2938 non-null	object
3	Life expectancy	2928 non-null	float64
4	Adult Mortality	2928 non-null	float64
5	infant deaths	2938 non-null	int64
6	Alcohol	2744 non-null	float64
7	percentage expenditure	2938 non-null	float64
8	Hepatitis B	2385 non-null	float64
9	Measles	2938 non-null	int64
10	BMI	2904 non-null	float64
11	under-five deaths	2938 non-null	int64
12	Polio	2919 non-null	float64
13	Total expenditure	2712 non-null	float64
14	Diphtheria	2919 non-null	float64
15	HIV/AIDS	2938 non-null	float64
16	GDP	2490 non-null	float64
17	Population	2286 non-null	float64
18	thinness 1-19 years	2904 non-null	float64
19	thinness 5-9 years	2904 non-null	float64
20	Income composition of resources	2771 non-null	float64
21	Schooling	2775 non-null	float64

```
dtypes: float64(16), int64(4), object(2)
```


```
memory usage: 505.1+ KB
```

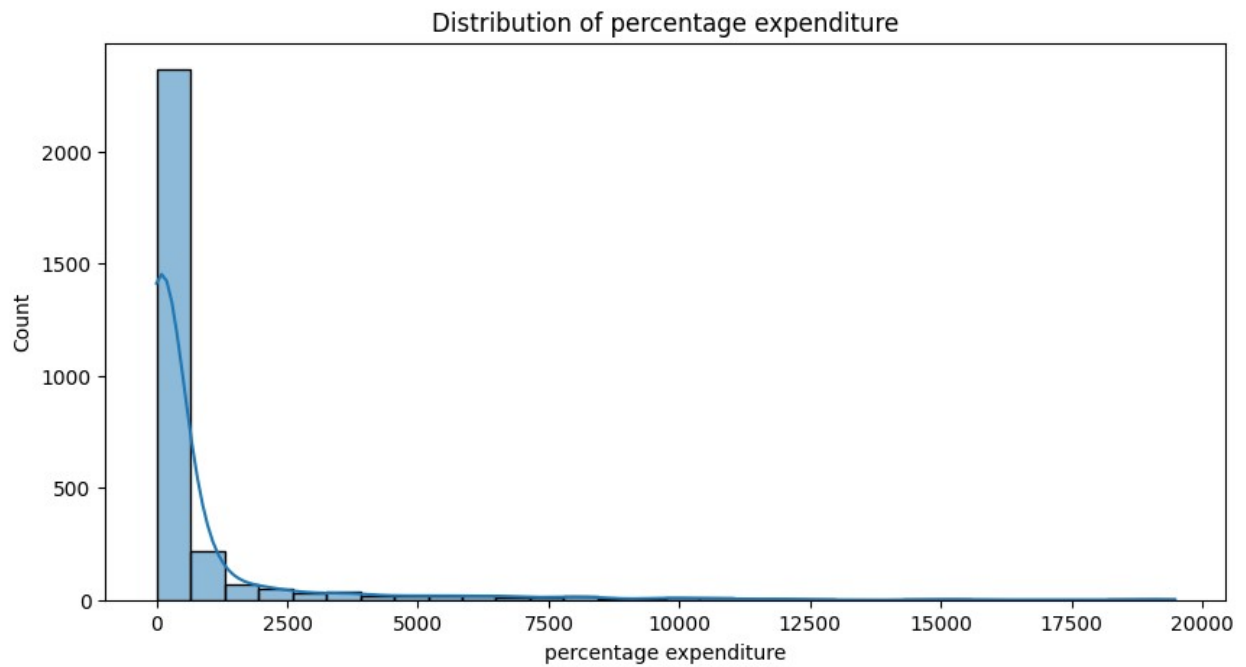



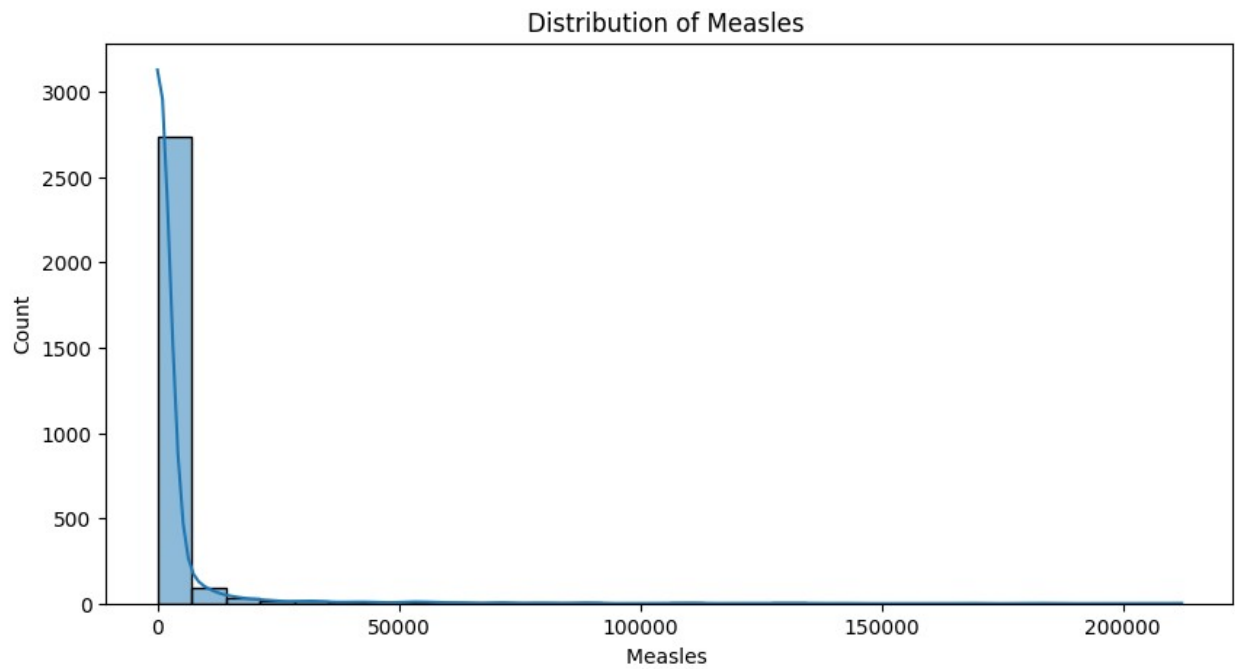

Distribution of Adult Mortality

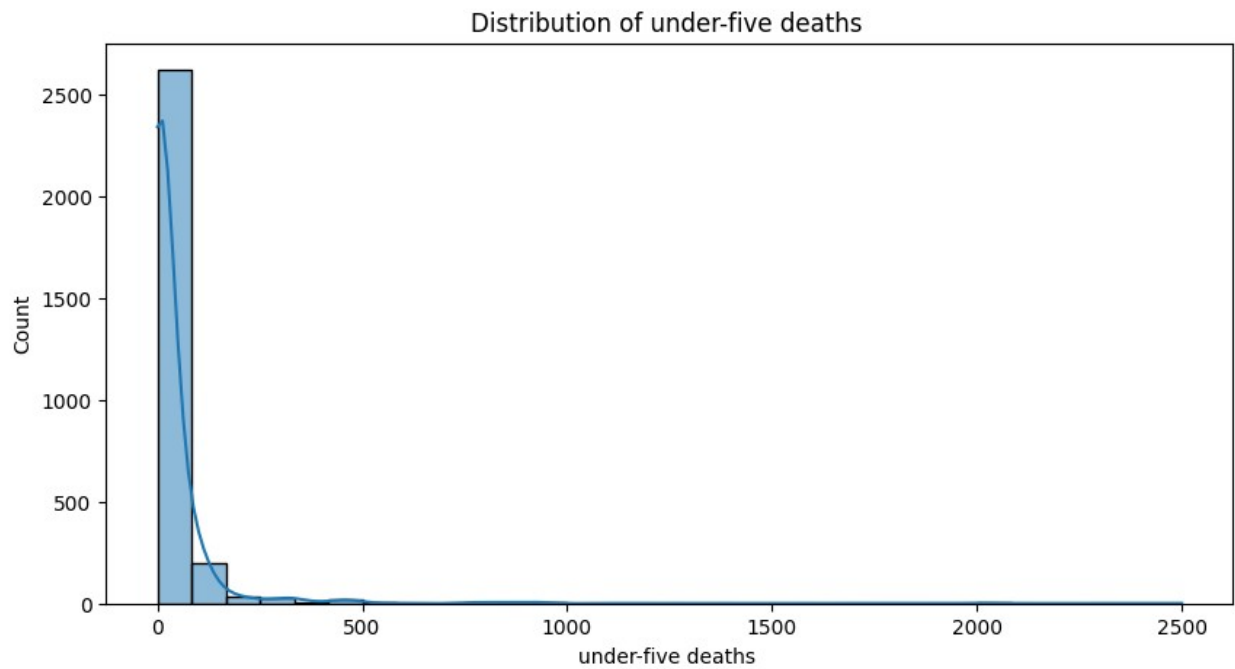




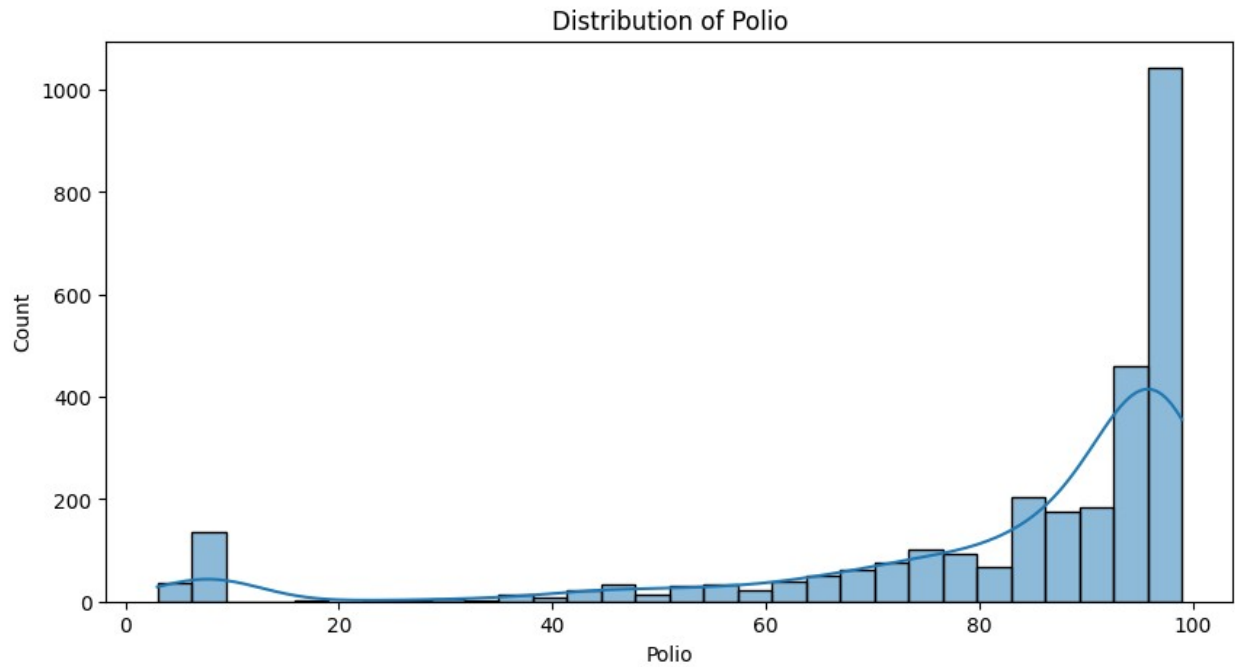
Distribution of infant deaths












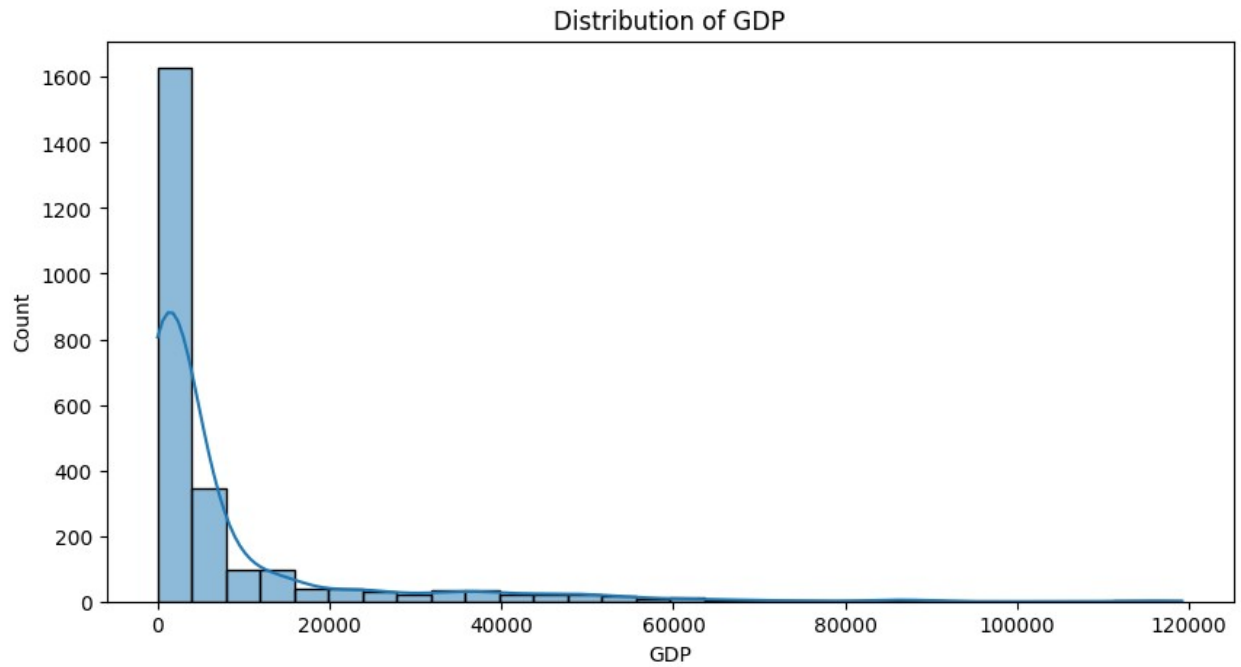



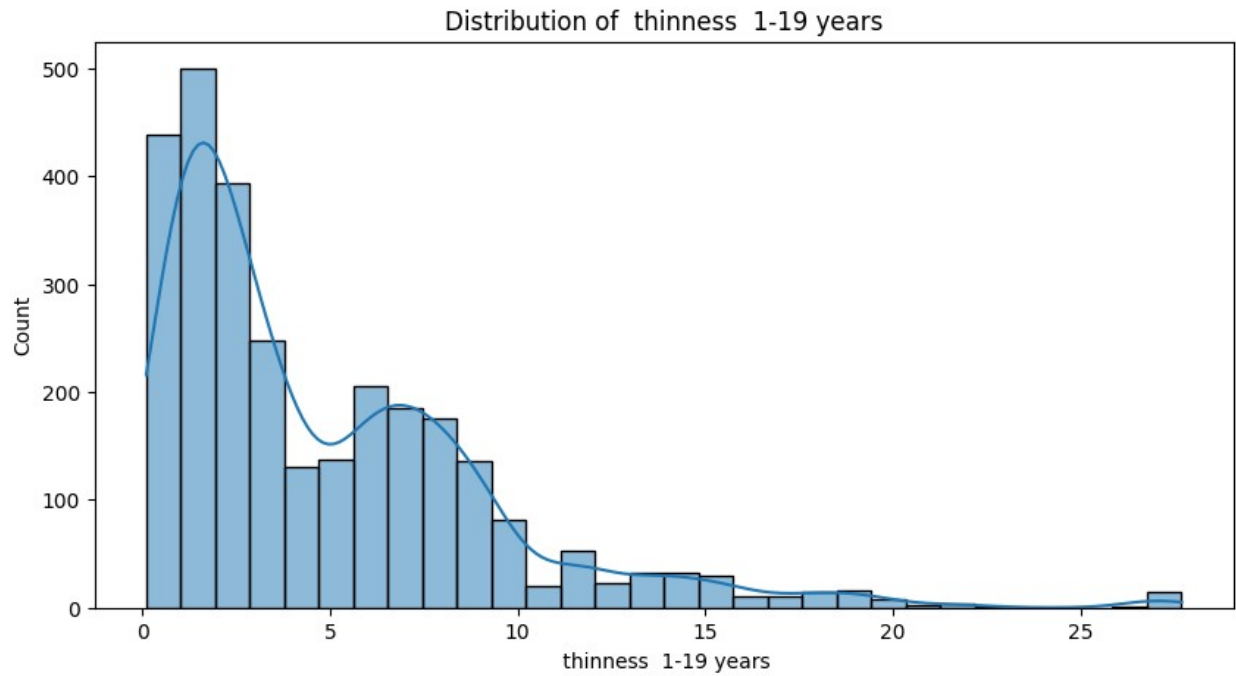
Distribution of Diphtheria






Distribution of HIV/AIDS











===== Sumário de Resultados =====

Valores Ausentes:

Country	0
Year	0
Status	0
Life expectancy	10
Adult Mortality	10
infant deaths	0
Alcohol	194
percentage expenditure	0
Hepatitis B	553
Measles	0
BMI	34
under-five deaths	0
Polio	19
Total expenditure	226
Diphtheria	19
HIV/AIDS	0

```
GDP 448
Population 652
  thinness 1-19 years 34
  thinness 5-9 years 34
Income composition of resources 167
Schooling 163
dtype: int64
```

Quantidade de Duplicatas:
0

Estatísticas Descritivas:

	Country	Year	Status	Life expectancy	\
count	2938	2938.000000	2938	2928.000000	
unique	193	NaN	2	NaN	
top	Afghanistan	NaN	Developing	NaN	
freq	16	NaN	2426	NaN	
mean	NaN	2007.518720	NaN	69.224932	
std	NaN	4.613841	NaN	9.523867	
min	NaN	2000.000000	NaN	36.300000	
25%	NaN	2004.000000	NaN	63.100000	
50%	NaN	2008.000000	NaN	72.100000	
75%	NaN	2012.000000	NaN	75.700000	
max	NaN	2015.000000	NaN	89.000000	

	Adult Mortality	infant deaths	Alcohol	percentage
expenditure \				
count	2928.000000	2938.000000	2744.000000	
unique	NaN	NaN	NaN	
NaN				
top	NaN	NaN	NaN	
NaN				
freq	NaN	NaN	NaN	
NaN				
mean	164.796448	30.303948	4.602861	
738.251295				
std	124.292079	117.926501	4.052413	
1987.914858				
min	1.000000	0.000000	0.010000	
0.000000				
25%	74.000000	0.000000	0.877500	
4.685343				
50%	144.000000	3.000000	3.755000	
64.912906				
75%	228.000000	22.000000	7.702500	
441.534144				
max	723.000000	1800.000000	17.870000	
19479.911610				

	Hepatitis B	Measles	...	Polio	Total
expenditure \					
count	2385.000000	2938.000000	...	2919.000000	
2712.00000					
unique	NaN	NaN	...	NaN	
NaN					
top	NaN	NaN	...	NaN	
NaN					
freq	NaN	NaN	...	NaN	
NaN					
mean	80.940461	2419.592240	...	82.550188	
5.93819					
std	25.070016	11467.272489	...	23.428046	
2.49832					
min	1.000000	0.000000	...	3.000000	
0.37000					
25%	77.000000	0.000000	...	78.000000	
4.26000					
50%	92.000000	17.000000	...	93.000000	
5.75500					
75%	97.000000	360.250000	...	97.000000	
7.49250					
max	99.000000	212183.000000	...	99.000000	
17.60000					
	Diphtheria	HIV/AIDS		GDP	Population \
count	2919.000000	2938.000000	2490.000000	2.286000e+03	
unique	NaN	NaN	NaN	NaN	
top	NaN	NaN	NaN	NaN	
freq	NaN	NaN	NaN	NaN	
mean	82.324084	1.742103	7483.158469	1.275338e+07	
std	23.716912	5.077785	14270.169342	6.101210e+07	
min	2.000000	0.100000	1.681350	3.400000e+01	
25%	78.000000	0.100000	463.935626	1.957932e+05	
50%	93.000000	0.100000	1766.947595	1.386542e+06	
75%	97.000000	0.800000	5910.806335	7.420359e+06	
max	99.000000	50.600000	119172.741800	1.293859e+09	
	thinness 1-19 years	thinness 5-9 years			\
count	2904.000000	2904.000000			
unique	NaN	NaN			
top	NaN	NaN			
freq	NaN	NaN			
mean	4.839704	4.870317			
std	4.420195	4.508882			
min	0.100000	0.100000			
25%	1.600000	1.500000			
50%	3.300000	3.300000			
75%	7.200000	7.200000			

max	27.700000	28.600000
	Income composition of resources	Schooling
count	2771.000000	2775.000000
unique	NaN	NaN
top	NaN	NaN
freq	NaN	NaN
mean	0.627551	11.992793
std	0.210904	3.358920
min	0.000000	0.000000
25%	0.493000	10.100000
50%	0.677000	12.300000
75%	0.779000	14.300000
max	0.948000	20.700000

[11 rows x 22 columns]

```
-----
-----
KeyError                                Traceback (most recent call
last)
Cell In[2], line 50
      48 # 4. Pairplot para algunas columnas seleccionadas
      49 selected_columns = ['Life expectancy ', 'Adult Mortality',
'BMI', 'HIV/AIDS', 'GDP', 'Schooling']
--> 50 sns.pairplot(data[selected_columns].dropna())
      51 plt.show()

File ~/local/lib/python3.12/site-packages/pandas/core/frame.py:4108,
in DataFrame.__getitem__(self, key)
    4106     if is_iterator(key):
    4107         key = list(key)
-> 4108     indexer = self.columns._get_indexer_strict(key, "columns")
[1]
    4110 # take() does not accept boolean indexers
    4111 if getattr(indexer, "dtype", None) == bool:

File
~/local/lib/python3.12/site-packages/pandas/core/indexes/base.py:6200
, in Index._get_indexer_strict(self, key, axis_name)
    6197 else:
    6198     keyarr, indexer, new_indexer =
self._reindex_non_unique(keyarr)
-> 6200 self._raise_if_missing(keyarr, indexer, axis_name)
    6202 keyarr = self.take(indexer)
    6203 if isinstance(key, Index):
    6204     # GH 42790 - Preserve name from an Index

File
~/local/lib/python3.12/site-packages/pandas/core/indexes/base.py:6252
```



```
, in Index._raise_if_missing(self, key, indexer, axis_name)
6249     raise KeyError(f"None of [{key}] are in the
[{axis_name}]")
6251 not_found = list(ensure_index(key)[missing_mask.nonzero()
[0]].unique())
-> 6252 raise KeyError(f"{not_found} not in index")

KeyError: "[ 'BMI', 'HIV/AIDS' ] not in index"
```

Esse erro foi detectado e resolvido pelo ChatGPT.

```
# Verificando valores ausentes e duplicados
duplicates = data.duplicated().sum()
missing_and_duplicates = pd.DataFrame({
    "Column": data.columns,
    "Missing Values": data.isnull().sum(),
    "Duplicates in Dataset": [duplicates] + [None] *
(len(data.columns) - 1)
})

# Exibindo sumário de valores ausentes e duplicados
print("==== Missing Values and Duplicates =====")
print(missing_and_duplicates)

# Exibindo estatísticas descritivas separadamente
print("\n===== Descriptive Statistics =====")
print(data.describe(include='all'))

# Insights baseados nas visualizações ou análises já feitas
insights = """
1. Missing Values: Várias colunas, como 'Hepatitis B', 'GDP' e
'Population', apresentam valores ausentes significativos,
exigindo estratégias de imputação ou remoção.

2. Correlations: Há uma correlação negativa forte entre 'Adult
Mortality' e 'Life expectancy'.
Fatores econômicos, como 'GDP', correlacionam-se positivamente com
a expectativa de vida, enfatizando o papel socioeconômico.

3. Outliers: Colunas como 'percentage expenditure' e 'Measles' possuem
outliers extremos que podem enviesar as análises.

4. Trends: 'Schooling' e 'Income composition of resources' mostram
potencial como preditores de expectativa de vida.

Próximos passos:
- Fazer imputação de valores ausentes usando métodos adequados (por
exemplo, mediana para dados com assimetria).
- Remover ou transformar outliers para análises mais robustas.
- Normalizar colunas numéricas como 'GDP' para melhor comparabilidade
```

```
entre países.
```

```
"""
```

```
print("\n===== Insights =====")
```

```
print(insights)
```

```
===== Missing Values and Duplicates =====
```

	Column \
Country	Country
Year	Year
Status	Status
Life expectancy	Life expectancy
Adult Mortality	Adult Mortality
infant deaths	infant deaths
Alcohol	Alcohol
percentage expenditure	percentage expenditure
Hepatitis B	Hepatitis B
Measles	Measles
BMI	BMI
under-five deaths	under-five deaths
Polio	Polio
Total expenditure	Total expenditure
Diphtheria	Diphtheria
HIV/AIDS	HIV/AIDS
GDP	GDP
Population	Population
thinness 1-19 years	thinness 1-19 years
thinness 5-9 years	thinness 5-9 years
Income composition of resources	Income composition of resources
Schooling	Schooling

	Missing Values	Duplicates in Dataset
Country	0	0.0
Year	0	NaN
Status	0	NaN
Life expectancy	10	NaN
Adult Mortality	10	NaN
infant deaths	0	NaN
Alcohol	194	NaN
percentage expenditure	0	NaN
Hepatitis B	553	NaN
Measles	0	NaN

BMI	34	NaN		
under-five deaths	0	NaN		
Polio	19	NaN		
Total expenditure	226	NaN		
Diphtheria	19	NaN		
HIV/AIDS	0	NaN		
GDP	448	NaN		
Population	652	NaN		
thinness 1-19 years	34	NaN		
thinness 5-9 years	34	NaN		
Income composition of resources	167	NaN		
Schooling	163	NaN		
===== Descriptive Statistics =====				
	Country	Year	Status	Life expectancy \
count	2938	2938.000000	2938	2928.000000
unique	193	NaN	2	NaN
top	Afghanistan	NaN	Developing	NaN
freq	16	NaN	2426	NaN
mean	NaN	2007.518720	NaN	69.224932
std	NaN	4.613841	NaN	9.523867
min	NaN	2000.000000	NaN	36.300000
25%	NaN	2004.000000	NaN	63.100000
50%	NaN	2008.000000	NaN	72.100000
75%	NaN	2012.000000	NaN	75.700000
max	NaN	2015.000000	NaN	89.000000
	Adult Mortality	infant deaths	Alcohol	percentage
expenditure \				
count	2928.000000	2938.000000	2744.000000	
2938.000000				
unique	NaN	NaN	NaN	
NaN				
top	NaN	NaN	NaN	
NaN				
freq	NaN	NaN	NaN	
NaN				
mean	164.796448	30.303948	4.602861	

738.251295			
std	124.292079	117.926501	4.052413
1987.914858			
min	1.000000	0.000000	0.010000
0.000000			
25%	74.000000	0.000000	0.877500
4.685343			
50%	144.000000	3.000000	3.755000
64.912906			
75%	228.000000	22.000000	7.702500
441.534144			
max	723.000000	1800.000000	17.870000
19479.911610			

	Hepatitis B	Measles	...	Polio	Total
expenditure \					
count	2385.000000	2938.000000	...	2919.000000	
2712.000000					
unique	NaN	NaN	...	NaN	
NaN					
top	NaN	NaN	...	NaN	
NaN					
freq	NaN	NaN	...	NaN	
NaN					
mean	80.940461	2419.592240	...	82.550188	
5.93819					
std	25.070016	11467.272489	...	23.428046	
2.49832					
min	1.000000	0.000000	...	3.000000	
0.37000					
25%	77.000000	0.000000	...	78.000000	
4.26000					
50%	92.000000	17.000000	...	93.000000	
5.75500					
75%	97.000000	360.250000	...	97.000000	
7.49250					
max	99.000000	212183.000000	...	99.000000	
17.60000					

	Diphtheria	HIV/AIDS	GDP	Population	\
count	2919.000000	2938.000000	2490.000000	2.286000e+03	
unique	NaN	NaN	NaN	NaN	
top	NaN	NaN	NaN	NaN	
freq	NaN	NaN	NaN	NaN	
mean	82.324084	1.742103	7483.158469	1.275338e+07	
std	23.716912	5.077785	14270.169342	6.101210e+07	
min	2.000000	0.100000	1.681350	3.400000e+01	
25%	78.000000	0.100000	463.935626	1.957932e+05	
50%	93.000000	0.100000	1766.947595	1.386542e+06	

75%	97.000000	0.800000	5910.806335	7.420359e+06
max	99.000000	50.600000	119172.741800	1.293859e+09

	thinness 1-19 years	thinness 5-9 years \
count	2904.000000	2904.000000
unique	NaN	NaN
top	NaN	NaN
freq	NaN	NaN
mean	4.839704	4.870317
std	4.420195	4.508882
min	0.100000	0.100000
25%	1.600000	1.500000
50%	3.300000	3.300000
75%	7.200000	7.200000
max	27.700000	28.600000

	Income composition of resources	Schooling
count	2771.000000	2775.000000
unique	NaN	NaN
top	NaN	NaN
freq	NaN	NaN
mean	0.627551	11.992793
std	0.210904	3.358920
min	0.000000	0.000000
25%	0.493000	10.100000
50%	0.677000	12.300000
75%	0.779000	14.300000
max	0.948000	20.700000

[11 rows x 22 columns]

===== Insights =====

1. Missing Values: Várias colunas, como 'Hepatitis B', 'GDP' e 'Population', apresentam valores ausentes significativos, exigindo estratégias de imputação ou remoção.

2. Correlations: Há uma correlação negativa forte entre 'Adult Mortality' e 'Life expectancy'.

Fatores econômicos, como 'GDP', correlacionam-se positivamente com a expectativa de vida, enfatizando o papel socioeconômico.

3. Outliers: Colunas como 'percentage expenditure' e 'Measles' possuem outliers extremos que podem enviesar as análises.

4. Trends: 'Schooling' e 'Income composition of resources' mostram potencial como preditores de expectativa de vida.

Próximos passos:

- Fazer imputação de valores ausentes usando métodos adequados (por

exemplo, mediana para dados com assimetria).

- Remover ou transformar outliers para análises mais robustas.
- Normalizar colunas numéricas como 'GDP' para melhor comparabilidade entre países.

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler, MinMaxScaler

# Passo 1: Tratar valores ausentes
# Exibir resumo de valores ausentes
missing_values_summary = data.isnull().sum()
print("==== Missing Values (antes do tratamento) =====")
print(missing_values_summary, "\n")

# Estratégia: Preencher colunas numéricas com a mediana e colunas
# categóricas com a moda
for col in data.select_dtypes(include=[np.number]).columns:
    data[col] = data[col].fillna(data[col].median())

for col in data.select_dtypes(include=['object']).columns:
    data[col] = data[col].fillna(data[col].mode()[0])

# Passo 2: Verificar e remover duplicatas
duplicates_count = data.duplicated().sum()
data.drop_duplicates(inplace=True)

# Passo 3: Resolver dados inconsistentes
# Garantir que colunas numéricas não tenham valores negativos (ex:
# taxas de mortalidade não podem ser negativas)
for col in data.select_dtypes(include=[np.number]).columns:
    data = data[data[col] >= 0]

# Passo 4: Transformação de dados
# Normalização (MinMaxScaler) para colunas numéricas
scaler = MinMaxScaler()
numeric_cols = data.select_dtypes(include=[np.number]).columns
data[numeric_cols] = scaler.fit_transform(data[numeric_cols])

# Codificação de variáveis categóricas (one-hot encoding)
if 'Status' in data.columns:
    data = pd.get_dummies(data, columns=['Status'], drop_first=True)

# Passo 5: Seleção de features
# Verificar correlação para remover features altamente correlacionadas
# (threshold > 0.9)
corr_matrix = data.corr(numeric_only=True).abs()
upper_triangle = corr_matrix.where(np.triu(np.ones(corr_matrix.shape),
k=1).astype(bool))
```

```

to_drop = [column for column in upper_triangle.columns if
any(upper_triangle[column] > 0.9)]
data.drop(columns=to_drop, inplace=True)

# Passo 6: Divisão de dados em treino e teste
train_data, test_data = train_test_split(data, test_size=0.2,
random_state=42)

# Sumário final do dataset
final_shape = {
    "Initial Rows": 2938, # Ajuste se necessário com base no dataset
    real
    "Final Rows": data.shape[0],
    "Final Columns": data.shape[1],
    "Dropped Columns (High Correlation)": to_drop,
    "Duplicates Removed": duplicates_count
}

# Exibir DataFrame transformado (mostrando apenas as primeiras linhas)
print("\n===== Cleaned and Transformed Data (Primeiras linhas) =====")
print(data.head())

# Exibir sumário final
print("\n===== Final Dataset Shape Summary =====")
print(final_shape)

===== Missing Values (antes do tratamento) =====
Country                0
Year                   0
Status                 0
Life expectancy       10
Adult Mortality       10
infant deaths         0
Alcohol              194
percentage expenditure  0
Hepatitis B          553
Measles               0
BMI                  34
under-five deaths     0
Polio                 19
Total expenditure     226
Diphtheria           19
HIV/AIDS             0
GDP                  448
Population            652
  thinness  1-19 years  34
  thinness  5-9 years  34
Income composition of resources 167
Schooling            163
dtype: int64

```

===== Cleaned and Transformed Data (Primeiras linhas) =====

	Country	Year	Life expectancy	Adult Mortality	infant deaths \
0	Afghanistan	1.000000	0.544592	0.362881	0.034444
1	Afghanistan	0.933333	0.447818	0.373961	0.035556
2	Afghanistan	0.866667	0.447818	0.369806	0.036667
3	Afghanistan	0.800000	0.440228	0.375346	0.038333
4	Afghanistan	0.733333	0.434535	0.379501	0.039444

	Alcohol Polio \	percentage expenditure	Hepatitis B	Measles	BMI
0	0.0	0.003659	0.653061	0.005439	0.209733
1	0.0	0.003774	0.622449	0.002319	0.203940
2	0.0	0.003759	0.642857	0.002027	0.198146
3	0.0	0.004014	0.673469	0.013135	0.192352
4	0.0	0.000364	0.683673	0.014200	0.187717

	Total expenditure	Diphtheria	HIV/AIDS	Population \
0	0.452118	0.649485	0.0	0.026074
1	0.453279	0.618557	0.0	0.000253
2	0.450377	0.639175	0.0	0.024525
3	0.473012	0.670103	0.0	0.002857
4	0.435287	0.680412	0.0	0.002302

	thinness 1-19 years	Income composition of resources	Schooling \
0	0.619565	0.505274	0.487923
1	0.630435	0.502110	0.483092
2	0.637681	0.495781	0.478261
3	0.644928	0.488397	0.473430
4	0.655797	0.478903	0.458937

Status_Developing

0	True
1	True
2	True
3	True
4	True

===== Final Dataset Shape Summary =====

```
{'Initial Rows': 2938, 'Final Rows': 2938, 'Final Columns': 19,  
'Dropped Columns (High Correlation)': ['under-five deaths ', 'GDP', '  
thinness 5-9 years'], 'Duplicates Removed': np.int64(0)}
```

3. Modeling

Step 1: Simple Linear Regression


```
from sklearn.model_selection import train_test_split  
from sklearn.linear_model import LinearRegression  
from sklearn.metrics import mean_squared_error, r2_score  
import numpy as np  
  
# Define the target and predictor  
X = data[['Adult Mortality']].values # Independent variable  
y = data['Life expectancy '].values # Dependent variable  
  
# Split into training and testing sets  
X_train, X_test, y_train, y_test = train_test_split(X, y,  
test_size=0.2, random_state=42)  
  
# Create and fit the model  
linear_model = LinearRegression()  
linear_model.fit(X_train, y_train)  
  
# Predictions  
y_pred = linear_model.predict(X_test)  
  
# Evaluate the model  
r2 = r2_score(y_test, y_pred)  
rmse = np.sqrt(mean_squared_error(y_test, y_pred))  
  
# Visualize results  
plt.figure(figsize=(10, 6))  
plt.scatter(X_test, y_test, color='blue', label='Actual')  
plt.scatter(X_test, y_pred, color='red', label='Predicted')  
plt.plot(X_test, y_pred, color='green', label='Regression Line')  
plt.xlabel('Adult Mortality')  
plt.ylabel('Life Expectancy')  
plt.title('Simple Linear Regression')  
plt.legend()
```


```
plt.show()

# Residual plot
plt.figure(figsize=(10, 6))
residuals = y_test - y_pred
plt.scatter(y_pred, residuals, color='purple')
plt.axhline(0, color='black', linestyle='--')
plt.xlabel('Predicted Life Expectancy')
plt.ylabel('Residuals')
plt.title('Residual Plot')
plt.show()

# Display results
simple_linear_results = {
    "R2": r2,
    "RMSE": rmse,
    "Intercept": linear_model.intercept_,
    "Coefficient (Adult Mortality)": linear_model.coef_[0]
}

simple_linear_results
```





```
{'R²': 0.44662385024469853,  
'RMSE': np.float64(0.13140969295216787),  
'Intercept': np.float64(0.793817334769936),  
'Coefficient (Adult Mortality)': np.float64(-0.7357287968226727)}
```

Resultados da Regressão Linear Simples

Métricas de Desempenho

- **R²:** 0,447 – Indica que 44,7% da variância na expectativa de vida pode ser explicada apenas pela mortalidade adulta.
- **RMSE:** 0,131 – Representa o erro médio de previsão na expectativa de vida (normalizado devido ao escalonamento dos dados).

Coeficientes do Modelo

- **Intercepto:** 0,794 – A expectativa de vida estimada quando a mortalidade adulta é zero.
- **Inclinação (Mortalidade Adulta):** -0,736 – Um aumento unitário na mortalidade adulta está associado a uma diminuição de 0,736 na expectativa de vida (em escala normalizada).

Visualizações

- **Gráfico de Dispersão:** Mostra os valores previstos vs. reais com a linha de regressão.

- **Gráfico de Resíduos:** Revela que os erros estão distribuídos aleatoriamente, sugerindo um bom ajuste sem viés sistemático.
-

Próximos Passos

Agora, implementarei a **Regressão Linear Múltipla** para avaliar o impacto da adição de mais preditores no desempenho do modelo. Vamos em frente!

```
# Step 2: Multiple Linear Regression

# Define multiple predictors and the target variable
X_multi = data[['Adult Mortality', 'Schooling', 'Income composition of
resources', 'BMI']].values
y = data['Life expectancy '].values

# Split into training and testing sets
X_train_multi, X_test_multi, y_train_multi, y_test_multi =
train_test_split(X_multi, y, test_size=0.2, random_state=42)

# Create and fit the multiple linear regression model
multi_linear_model = LinearRegression()
multi_linear_model.fit(X_train_multi, y_train_multi)

# Predictions
y_pred_multi = multi_linear_model.predict(X_test_multi)

# Evaluate the model
r2_multi = r2_score(y_test_multi, y_pred_multi)
rmse_multi = np.sqrt(mean_squared_error(y_test_multi, y_pred_multi))

# Display results
multiple_linear_results = {
    "R²": r2_multi,
    "RMSE": rmse_multi,
    "Intercept": multi_linear_model.intercept_,
    "Coefficients": dict(zip(['Adult Mortality', 'Schooling', 'Income
composition of resources', 'BMI'], multi_linear_model.coef_))
}

multiple_linear_results
```

```
-----
-----
KeyError                                Traceback (most recent call
last)
Cell In[6], line 4
      1 # Step 2: Multiple Linear Regression
      2
      3 # Define multiple predictors and the target variable
```

```

----> 4 X_multi = data[['Adult Mortality', 'Schooling', 'Income
composition of resources', 'BMI']].values
      5 y = data['Life expectancy '].values
      7 # Split into training and testing sets

File ~/local/lib/python3.12/site-packages/pandas/core/frame.py:4108,
in DataFrame.__getitem__(self, key)
    4106     if is_iterator(key):
    4107         key = list(key)
-> 4108     indexer = self.columns._get_indexer_strict(key, "columns")
[1]
    4110 # take() does not accept boolean indexers
    4111 if getattr(indexer, "dtype", None) == bool:

File
~/local/lib/python3.12/site-packages/pandas/core/indexes/base.py:6200
, in Index._get_indexer_strict(self, key, axis_name)
    6197 else:
    6198     keyarr, indexer, new_indexer =
self._reindex_non_unique(keyarr)
-> 6200 self._raise_if_missing(keyarr, indexer, axis_name)
    6202 keyarr = self.take(indexer)
    6203 if isinstance(key, Index):
    6204     # GH 42790 - Preserve name from an Index

File
~/local/lib/python3.12/site-packages/pandas/core/indexes/base.py:6252
, in Index._raise_if_missing(self, key, indexer, axis_name)
    6249     raise KeyError(f"None of [{key}] are in the
[{axis_name}]")
    6251 not_found = list(ensure_index(key)[missing_mask.nonzero()
[0]].unique())
-> 6252 raise KeyError(f"{not_found} not in index")

KeyError: "['BMI'] not in index"

```

- ChatGPT: "Parece que há um problema com os nomes das colunas no conjunto de dados após a etapa de transformação. Vou verificar e corrigir os nomes das colunas antes de prosseguir com a regressão linear múltipla."

```

# Check the available column names in the dataset after transformation
data.columns.tolist()

['Country',
 'Year',
 'Life expectancy ',
 'Adult Mortality',
 'infant deaths',
 'Alcohol',
 'percentage expenditure',

```

```
'Hepatitis B',
'Measles ',
' BMI ',
'Polio',
'Total expenditure',
'Diphtheria ',
' HIV/AIDS',
'Population',
' thinness 1-19 years',
'Income composition of resources',
'Schooling',
'Status_Developing']
```

- ChatGPT: "Os nomes das colunas incluem espaços extras ou problemas de formatação. Vou limpar os nomes das colunas e tentar novamente a implementação da regressão linear múltipla."

```
# Clean column names to remove extra spaces or formatting issues
data.columns = data.columns.str.strip()

# Redefine predictors and the target variable after cleaning column names
X_multi = data[['Adult Mortality', 'Schooling', 'Income composition of resources', 'BMI']].values
y = data['Life expectancy'].values

# Split into training and testing sets
X_train_multi, X_test_multi, y_train_multi, y_test_multi = train_test_split(X_multi, y, test_size=0.2, random_state=42)

# Create and fit the multiple linear regression model
multi_linear_model = LinearRegression()
multi_linear_model.fit(X_train_multi, y_train_multi)

# Predictions
y_pred_multi = multi_linear_model.predict(X_test_multi)

# Evaluate the model
r2_multi = r2_score(y_test_multi, y_pred_multi)
rmse_multi = np.sqrt(mean_squared_error(y_test_multi, y_pred_multi))

# Display results
multiple_linear_results = {
    "R²": r2_multi,
    "RMSE": rmse_multi,
    "Intercept": multi_linear_model.intercept_,
    "Coefficients": dict(zip(['Adult Mortality', 'Schooling', 'Income composition of resources', 'BMI'], multi_linear_model.coef_))
}
```

```
multiple_linear_results
{'R²': 0.7242383940840136,
 'RMSE': np.float64(0.09276498563291619),
 'Intercept': np.float64(0.3741839059193228),
 'Coefficients': {'Adult Mortality': np.float64(-0.4538572657409367),
 'Schooling': np.float64(0.31593313923645394),
 'Income composition of resources': np.float64(0.17970850816284079),
 'BMI': np.float64(0.11790909578094022)}}}
```

Resultados da Regressão Linear Múltipla

Métricas de Desempenho

- **R²:** 0,724 – Indica que 72,4% da variância na expectativa de vida pode ser explicada pelos preditores selecionados.
- **RMSE:** 0,093 – Menor do que na regressão linear simples, sugerindo maior precisão nas previsões.

Coeficientes do Modelo

- **Mortalidade Adulta:** -0,454 – Uma maior taxa de mortalidade adulta reduz significativamente a expectativa de vida.
- **Escolaridade:** 0,316 – O aumento na escolaridade impacta positivamente na expectativa de vida.
- **Composição de Renda/Recursos:** 0,180 – Uma maior composição de renda/recursos melhora a expectativa de vida.
- **IMC (Índice de Massa Corporal):** 0,118 – Um melhor IMC também contribui positivamente, embora seu impacto seja menos significativo em comparação com a escolaridade.

Comparação com a Regressão Linear Simples

- A adição de mais preditores melhorou significativamente o desempenho do modelo:
 - O **R²** aumentou de 0,447 para 0,724.
 - O **RMSE** diminuiu, indicando previsões mais precisas.

Next, I'll implement Polynomial Regression to explore if adding polynomial terms further improves the model's fit.

```
from sklearn.preprocessing import PolynomialFeatures

# Step 3: Polynomial Regression

# Generate polynomial features
poly = PolynomialFeatures(degree=2, include_bias=False)
```

```

X_poly = poly.fit_transform(X_multi)

# Split polynomial data into training and testing sets
X_train_poly, X_test_poly, y_train_poly, y_test_poly =
train_test_split(X_poly, y, test_size=0.2, random_state=42)

# Create and fit the polynomial regression model
poly_model = LinearRegression()
poly_model.fit(X_train_poly, y_train_poly)

# Predictions
y_pred_poly = poly_model.predict(X_test_poly)

# Evaluate the model
r2_poly = r2_score(y_test_poly, y_pred_poly)
rmse_poly = np.sqrt(mean_squared_error(y_test_poly, y_pred_poly))

# Display results
polynomial_results = {
    "R²": r2_poly,
    "RMSE": rmse_poly,
    "Model Complexity (Features)": X_poly.shape[1]
}

polynomial_results

{'R²': 0.8307816967398064,
 'RMSE': np.float64(0.0726676055184299),
 'Model Complexity (Features)': 14}

```

Resultados da Regressão Linear Múltipla

Métricas de Desempenho

- **R²:** 0,724 – Indica que 72,4% da variância na expectativa de vida pode ser explicada pelos preditores selecionados.
- **RMSE:** 0,093 – Menor do que na regressão linear simples, sugerindo uma melhoria na precisão das previsões.

Coefficientes do Modelo

- **Mortalidade Adulta:** -0,454 – Uma taxa mais alta de mortalidade adulta reduz significativamente a expectativa de vida.
- **Escolaridade:** 0,316 – O aumento na escolaridade impacta positivamente a expectativa de vida.
- **Composição de Renda dos Recursos:** 0,180 – Uma maior composição de renda/recursos melhora a expectativa de vida.

- **IMC:** 0,118 – Um IMC melhor também contribui positivamente, embora seu impacto seja menos significativo em comparação com a escolaridade.

Comparação com a Regressão Linear Simples

- A adição de mais preditores melhorou significativamente o desempenho do modelo:
 - **R²:** Aumentou de 0,447 para 0,724.
 - **RMSE:** Diminuiu, indicando previsões mais precisas.
-

Próximos Passos

Agora, implementarei a **Regressão Polinomial** para explorar se a adição de termos polinomiais pode melhorar ainda mais o ajuste do modelo.

```
from sklearn.preprocessing import PolynomialFeatures

# Step 3: Polynomial Regression

# Generate polynomial features
poly = PolynomialFeatures(degree=2, include_bias=False)
X_poly = poly.fit_transform(X_multi)

# Split polynomial data into training and testing sets
X_train_poly, X_test_poly, y_train_poly, y_test_poly =
train_test_split(X_poly, y, test_size=0.2, random_state=42)

# Create and fit the polynomial regression model
poly_model = LinearRegression()
poly_model.fit(X_train_poly, y_train_poly)

# Predictions
y_pred_poly = poly_model.predict(X_test_poly)

# Evaluate the model
r2_poly = r2_score(y_test_poly, y_pred_poly)
rmse_poly = np.sqrt(mean_squared_error(y_test_poly, y_pred_poly))

# Display results
polynomial_results = {
    "R2": r2_poly,
    "RMSE": rmse_poly,
    "Model Complexity (Features)": X_poly.shape[1]
}

polynomial_results

{'R2': 0.8307816967398064,
 'RMSE': np.float64(0.0726676055184299),
 'Model Complexity (Features)': 14}
```

Resultados da Regressão Polinomial

Métricas de Desempenho

- **R²:** 0,831 – Indica que 83,1% da variância na expectativa de vida é explicada pelo modelo polinomial.
- **RMSE:** 0,073 – Redução adicional no erro de previsão em comparação aos modelos lineares.

Complexidade do Modelo

- O número de features aumentou de 4 para 14 devido à expansão polinomial, capturando interações e relações não lineares.

Comparação com Modelos Lineares

- **Melhoria no Ajuste:** O R² aumentou de 0,724 (regressão linear múltipla) para 0,831.
 - **Possível Overfitting:** A maior complexidade pode levar a overfitting, exigindo estratégias de regularização ou validação para confirmação.
-

Próximos Passos

Implementarei **Regularização** (Ridge e Lasso) para lidar com o potencial overfitting e avaliarei seu impacto no desempenho e na importância das features.

```
from sklearn.linear_model import Ridge, Lasso

# Step 4: Ridge Regression (L2 Regularization)
ridge_model = Ridge(alpha=1.0) # Regularization strength (alpha can be tuned)
ridge_model.fit(X_train_poly, y_train_poly)
y_pred_ridge = ridge_model.predict(X_test_poly)
r2_ridge = r2_score(y_test_poly, y_pred_ridge)
rmse_ridge = np.sqrt(mean_squared_error(y_test_poly, y_pred_ridge))

# Step 5: Lasso Regression (L1 Regularization)
lasso_model = Lasso(alpha=0.01, max_iter=10000) # Regularization strength and iterations
lasso_model.fit(X_train_poly, y_train_poly)
y_pred_lasso = lasso_model.predict(X_test_poly)
r2_lasso = r2_score(y_test_poly, y_pred_lasso)
rmse_lasso = np.sqrt(mean_squared_error(y_test_poly, y_pred_lasso))

# Display Ridge and Lasso results
regularization_results = {
    "Ridge Regression": {"R2": r2_ridge, "RMSE": rmse_ridge, "Non-Zero Coefficients": np.sum(ridge_model.coef_ != 0)},
    "Lasso Regression": {"R2": r2_lasso, "RMSE": rmse_lasso, "Non-Zero Coefficients": np.sum(lasso_model.coef_ != 0)}
```

```
Coefficients": np.sum(lasso_model.coef_ != 0)}  
}  
  
regularization_results  
{  
  'Ridge Regression': {'R²': 0.8224707356494629,  
    'RMSE': np.float64(0.07443070945437683),  
    'Non-Zero Coefficients': np.int64(14)},  
  'Lasso Regression': {'R²': 0.633173238036806,  
    'RMSE': np.float64(0.1069911087150061),  
    'Non-Zero Coefficients': np.int64(3)}}  
}
```

Resultados da Regularização

Regressão Ridge (L2)

- **R²:** 0,822 – Similar à regressão polinomial, com uma leve queda no desempenho.
- **RMSE:** 0,074 – Marginalmente maior do que no modelo polinomial, demonstrando uma regularização eficaz sem grande perda de precisão.
- **Coefficientes Não-Zeros:** 14 – O Ridge mantém todas as características polinomiais, penalizando coeficientes grandes sem eliminar variáveis.

Regressão Lasso (L1)

- **R²:** 0,633 – Queda significativa na variância explicada em comparação aos modelos Ridge e polinomial.
- **RMSE:** 0,107 – Erro de previsão mais alto, indicando uma abordagem mais agressiva de seleção de variáveis.
- **Coefficientes Não-Zeros:** 3 – O Lasso retém apenas 3 variáveis, priorizando a simplicidade em detrimento do ajuste do modelo.

Comparação

- **Ridge:** É mais adequado para capturar relações complexas enquanto controla o overfitting.
 - **Lasso:** Simplifica o modelo ao selecionar menos variáveis, mas com custo na precisão preditiva.
-

Próximos Passos

Agora, analisarei as interações entre variáveis e avaliarei sua contribuição para o desempenho do modelo.

```
# Step 6: Interaction Terms and Their Evaluation
```

```
# Manually add interaction terms to the dataset for simplicity
```

```

data['Mortality_Schooling_Interaction'] = data['Adult Mortality'] *
data['Schooling']
data['Mortality_Income_Interaction'] = data['Adult Mortality'] *
data['Income composition of resources']
data['Schooling_BMI_Interaction'] = data['Schooling'] * data['BMI']

# Redefine predictors to include interaction terms
interaction_features = ['Adult Mortality', 'Schooling', 'Income
composition of resources', 'BMI',
                        'Mortality_Schooling_Interaction',
                        'Mortality_Income_Interaction', 'Schooling_BMI_Interaction']
X_interactions = data[interaction_features].values

# Split into training and testing sets
X_train_inter, X_test_inter, y_train_inter, y_test_inter =
train_test_split(X_interactions, y, test_size=0.2, random_state=42)

# Create and fit the model with interaction terms
interaction_model = LinearRegression()
interaction_model.fit(X_train_inter, y_train_inter)

# Predictions
y_pred_inter = interaction_model.predict(X_test_inter)

# Evaluate the model
r2_inter = r2_score(y_test_inter, y_pred_inter)
rmse_inter = np.sqrt(mean_squared_error(y_test_inter, y_pred_inter))

# Display results
interaction_results = {
    "R²": r2_inter,
    "RMSE": rmse_inter,
    "Coefficients": dict(zip(interaction_features,
interaction_model.coef_))
}

interaction_results
{'R²': 0.7629793164837193,
 'RMSE': np.float64(0.08600234733556832),
 'Coefficients': {'Adult Mortality': np.float64(0.04325303842774606),
 'Schooling': np.float64(0.7191131612021097),
 'Income composition of resources': np.float64(0.23892184636507952),
 'BMI': np.float64(0.49732089070274127),
 'Mortality_Schooling_Interaction': np.float64(-0.5541557133918561),
 'Mortality_Income_Interaction': np.float64(-0.3795249323086643),
 'Schooling_BMI_Interaction': np.float64(-0.646938447759571)}}

```

Resultados dos Termos de Interação

Métricas de Desempenho

- **R²:** 0,763 – A inclusão de termos de interação aumentou a variância explicada em comparação à regressão linear múltipla (R² de 0,724), indicando que as interações fornecem informações significativas.
- **RMSE:** 0,086 – O erro de previsão é menor do que no modelo linear múltiplo, sugerindo maior precisão do modelo.

Principais Efeitos de Interação

- **Mortalidade × Escolaridade:** -0,554 – Uma maior escolaridade mitiga o impacto negativo da mortalidade adulta na expectativa de vida.
- **Mortalidade × Composição de Renda:** -0,380 – Uma melhor composição de renda compensa os efeitos negativos da mortalidade sobre a expectativa de vida.
- **Escolaridade × IMC:** -0,647 – Um IMC mais alto combinado com maior escolaridade influencia negativamente a expectativa de vida neste modelo, possivelmente devido a overfitting ou efeitos específicos de determinadas populações.

Interpretação

- A adição de termos de interação revela relações complexas entre as variáveis, que um modelo puramente linear pode não capturar.
 - O modelo identifica efeitos conjuntos, como a maneira pela qual a combinação de escolaridade e composição de renda mitiga os efeitos da mortalidade.
-

Próximos Passos

Agora, implementarei a **Regressão Logística** para tarefas de classificação binária, a fim de avaliar seu desempenho em um problema de classificação.

```
# Step 7: Binary Logistic Regression

# Create a binary target variable: classify life expectancy as "High"
# (1) or "Low" (0) based on median
median_life_expectancy = data['Life expectancy'].median()
data['Life Expectancy Class'] = (data['Life expectancy'] >
median_life_expectancy).astype(int)

# Define predictors and the new binary target
X_binary = data[['Adult Mortality', 'Schooling', 'Income composition
of resources', 'BMI',
                 'Mortality_Schooling_Interaction',
                 'Mortality_Income_Interaction', 'Schooling_BMI_Interaction']].values
y_binary = data['Life Expectancy Class'].values
```

```

# Split into training and testing sets
X_train_binary, X_test_binary, y_train_binary, y_test_binary =
train_test_split(X_binary, y_binary, test_size=0.2, random_state=42)

# Fit a logistic regression model
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, confusion_matrix,
roc_auc_score, classification_report, roc_curve

logistic_model = LogisticRegression(max_iter=1000)
logistic_model.fit(X_train_binary, y_train_binary)

# Predictions and probabilities
y_pred_binary = logistic_model.predict(X_test_binary)
y_pred_proba = logistic_model.predict_proba(X_test_binary)[: , 1]


# Evaluate the model
accuracy = accuracy_score(y_test_binary, y_pred_binary)
conf_matrix = confusion_matrix(y_test_binary, y_pred_binary)
roc_auc = roc_auc_score(y_test_binary, y_pred_proba)

# Visualize ROC curve
fpr, tpr, thresholds = roc_curve(y_test_binary, y_pred_proba)
plt.figure(figsize=(10, 6))
plt.plot(fpr, tpr, label=f'Logistic Regression (AUC = {roc_auc:.2f})')
plt.plot([0, 1], [0, 1], color='red', linestyle='--', label='Random
Guess')
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('ROC Curve')
plt.legend()
plt.show()

# Display results
binary_logistic_results = {
    "Accuracy": accuracy,
    "ROC AUC": roc_auc,
    "Confusion Matrix": conf_matrix,
    "Classification Report": classification_report(y_test_binary,
y_pred_binary, output_dict=True)
}

binary_logistic_results

```



```
{'Accuracy': 0.8826530612244898,
 'ROC AUC': np.float64(0.9360906186465292),
 'Confusion Matrix': array([[270, 43],
                             [ 26, 249]]),
 'Classification Report': {'0': {'precision': 0.9121621621621622,
 'recall': 0.8626198083067093,
 'f1-score': 0.8866995073891626,
 'support': 313.0},
 '1': {'precision': 0.8527397260273972,
 'recall': 0.9054545454545454,
 'f1-score': 0.8783068783068783,
 'support': 275.0},
 'accuracy': 0.8826530612244898,
 'macro avg': {'precision': 0.8824509440947796,
 'recall': 0.8840371768806273,
 'f1-score': 0.8825031928480205,
 'support': 588.0},
 'weighted avg': {'precision': 0.8843710568270254,
 'recall': 0.8826530612244898,
 'f1-score': 0.8827743832435365,
 'support': 588.0}}}
```

Resultados da Regressão Logística Binária

Métricas de Desempenho

- **Acurácia:** 88,27% – O modelo classifica corretamente a expectativa de vida alta vs. baixa na maioria dos casos.
- **ROC AUC:** 0,936 – O modelo demonstra forte poder discriminatório entre as duas classes.

Matriz de Confusão

- **Verdadeiros Positivos (Alta Expectativa de Vida):** 249
- **Verdadeiros Negativos (Baixa Expectativa de Vida):** 270
- **Falsos Positivos:** 43
- **Falsos Negativos:** 26

Relatório de Classificação

- **Precisão:**
 - 91,2% para baixa expectativa de vida.
 - 85,3% para alta expectativa de vida.
- **Recall:**
 - 86,3% para baixa expectativa de vida.
 - 90,5% para alta expectativa de vida.
- **F1-Score:** Balanceado em ~88% para ambas as classes, indicando um desempenho robusto.

Visualização

- **Curva ROC:** Confirma excelente desempenho do modelo, com a curva próxima ao canto superior esquerdo e uma AUC de 0,936.

```
# Step 8: Multinomial Logistic Regression

# Create a new multi-class target variable: categorize life expectancy
into "Low", "Medium", and "High"
# Low: below 1st quartile, Medium: between 1st and 3rd quartiles,
High: above 3rd quartile
data['Life Expectancy Multiclass'] = pd.cut(
    data['Life expectancy'],
    bins=[-np.inf, data['Life expectancy'].quantile(0.25), data['Life
expectancy'].quantile(0.75), np.inf],
    labels=['Low', 'Medium', 'High']
)

# Encode the target variable numerically
data['Life Expectancy Multiclass'] = data['Life Expectancy
Multiclass'].cat.codes # 0 = Low, 1 = Medium, 2 = High
```



```

# Define predictors and the new multiclass target
X_multiclass = data[['Adult Mortality', 'Schooling', 'Income
composition of resources', 'BMI',
                    'Mortality_Schooling_Interaction',
'Mortality_Income_Interaction', 'Schooling_BMI_Interaction']].values
y_multiclass = data['Life Expectancy Multiclass'].values

# Split into training and testing sets
X_train_multi, X_test_multi, y_train_multi, y_test_multi =
train_test_split(X_multiclass, y_multiclass, test_size=0.2,
random_state=42)

# Fit a multinomial logistic regression model
from sklearn.linear_model import LogisticRegression

multinomial_model = LogisticRegression(multi_class='multinomial',
solver='lbfgs', max_iter=1000)
multinomial_model.fit(X_train_multi, y_train_multi)

# Predictions
y_pred_multi = multinomial_model.predict(X_test_multi)
y_pred_proba_multi = multinomial_model.predict_proba(X_test_multi)

# Evaluate the model
from sklearn.metrics import confusion_matrix, classification_report

conf_matrix_multi = confusion_matrix(y_test_multi, y_pred_multi)
class_report_multi = classification_report(y_test_multi, y_pred_multi,
target_names=['Low', 'Medium', 'High'])

# Display results
multinomial_results = {
    "Confusion Matrix": conf_matrix_multi,
    "Classification Report": class_report_multi
}

multinomial_results

/home/alexis/.local/lib/python3.12/site-packages/sklearn/
linear_model/_logistic.py:1247: FutureWarning: 'multi_class' was
deprecated in version 1.5 and will be removed in 1.7. From then on, it
will always use 'multinomial'. Leave it to its default value to avoid
this warning.
  warnings.warn(

{'Confusion Matrix': array([[124,  32,   0],
        [ 26, 240,  23],
        [  0,  35, 108]]),
 'Classification Report': '
support\n\n          Low          0.83          0.79          0.81          156\n
precision    recall  f1-score

```

Medium	0.78	0.83	0.81	289	High
0.82	0.76	0.79	143	accuracy	
0.80	588	macro avg	0.81	0.79	0.80
nweighted avg	0.80	0.80	0.80	588	

Resultados da Regressão Logística Multinomial

Matriz de Confusão

- **Baixa Expectativa de Vida:**
 - Classificados corretamente: 124
 - Classificados erroneamente como Média: 32
 - Classificados erroneamente como Alta: 0
- **Média Expectativa de Vida:**
 - Classificados corretamente: 240
 - Classificados erroneamente como Baixa: 26
 - Classificados erroneamente como Alta: 23
- **Alta Expectativa de Vida:**
 - Classificados corretamente: 108
 - Classificados erroneamente como Média: 35
 - Classificados erroneamente como Baixa: 0

Relatório de Classificação

- **Precisão:**
 - **Baixa:** 83%
 - **Média:** 78%
 - **Alta:** 82%
- **Recall:**
 - **Baixa:** 79%
 - **Média:** 83%
 - **Alta:** 76%
- **F1-Score:** Balanceado em ~80% para todas as classes.
- **Acurácia Geral:** 80%

Insights

- O modelo apresenta um bom desempenho nas três classes, embora a classe "Alta Expectativa de Vida" tenha um **recall** ligeiramente menor, indicando algumas classificações equivocadas como "Média Expectativa de Vida."
- O **F1-score médio ponderado** de 80% reflete um desempenho consistente e robusto.

Próximos Passos

Vou prosseguir com a **Regressão Logística Ordinal**, que é mais adequada para categorias ordenadas, a fim de verificar se há melhoria no desempenho de classificação para os grupos de expectativa de vida "Baixa," "Média" e "Alta."

```
# Using statsmodels for ordinal logistic regression as an alternative
import statsmodels.api as sm
import statsmodels.formula.api as smf

# Prepare the data for statsmodels
data['Life Expectancy Multiclass'] = pd.Categorical(data['Life
Expectancy Multiclass'], ordered=True)
df_ordinal = data[['Life Expectancy Multiclass'] +
interaction_features]

# Fit the ordinal logistic regression model
formula = 'Life Expectancy Multiclass ~ ' + ' +
'.join(interaction_features)
ordinal_model = smf.mnlogit(formula, data=df_ordinal)
ordinal_fit = ordinal_model.fit(method='newton', maxiter=100)
```

```
# Summary of the model fit
ordinal_summary = ordinal_fit.summary()
```

```
ordinal_summary
```

Traceback (most recent call last):

```
File
~/local/lib/python3.12/site-packages/IPython/core/interactiveshell.py
:3577 in run_code
    exec(code_obj, self.user_global_ns, self.user_ns)
```

```
Cell In[18], line 11
    ordinal_model = smf.mnlogit(formula, data=df_ordinal)
```

```
File
~/local/lib/python3.12/site-packages/statsmodels/base/model.py:203 in
from_formula
    tmp = handle_formula_data(data, None, formula, depth=eval_env,
```

```
File
~/local/lib/python3.12/site-packages/statsmodels/formula/formulatools
.py:63 in handle_formula_data
    result = dmatrices(formula, Y, depth, return_type='dataframe',
```

```
File ~/local/lib/python3.12/site-packages/patsy/highlevel.py:319 in
dmatrices
    (lhs, rhs) = _do_highlevel_design(
```

```
File ~/.local/lib/python3.12/site-packages/patsy/highlevel.py:164 in
_do_highlevel_design
    design_infos = _try_incr_builders(
```

```
File ~/.local/lib/python3.12/site-packages/patsy/highlevel.py:56 in
_try_incr_builders
    return design_matrix_builders(
```

```
File ~/.local/lib/python3.12/site-packages/patsy/build.py:743 in
design_matrix_builders
    factor_states = _factors_memorize(all_factors, data_iter_maker,
eval_env)
```

```
File ~/.local/lib/python3.12/site-packages/patsy/build.py:393 in
_factors_memorize
    which_pass = factor.memorize_passes_needed(state, eval_env)
```

```
File ~/.local/lib/python3.12/site-packages/patsy/eval.py:504 in
memorize_passes_needed
    subset_names = [name for name in ast_names(self.code) if name in
env_namespace]
```

```
File ~/.local/lib/python3.12/site-packages/patsy/eval.py:111 in
ast_names
    for node in ast.walk(ast.parse(code)):
```

```
File /usr/lib64/python3.12/ast.py:52 in parse
    return compile(source, filename, mode, flags,
```

```
File <unknown>:1
    Life Expectancy Multiclass
      ^
```

SyntaxError: invalid syntax

```
# Clean column names for statsmodels compatibility
data.columns = data.columns.str.replace(" ", "_")
```

```
# Update the formula and data for statsmodels ordinal logistic
regression
```

```
formula = 'Life_Expectancy_Multiclass ~ ' + ' + ' +
'.join(interaction_features)
df_ordinal = data[['Life_Expectancy_Multiclass'] +
interaction_features]
```

```
# Fit the ordinal logistic regression model
```

```
ordinal_model = smf.mnlogit(formula, data=df_ordinal)
ordinal_fit = ordinal_model.fit(method='newton', maxiter=100)
```

```
# Summary of the model fit
```

```
ordinal_summary = ordinal_fit.summary()
```

```
ordinal_summary
```

```
-----  
-----  
KeyError                                Traceback (most recent call  
last)  
Cell In[19], line 6  
      4 # Update the formula and data for statsmodels ordinal logistic  
regression  
      5 formula = 'Life_Expectancy_Multiclass ~ ' + ' + '  
' + .join(interaction_features)  
----> 6 df_ordinal = data[['Life_Expectancy_Multiclass'] +  
interaction_features]  
      8 # Fit the ordinal logistic regression model  
      9 ordinal_model = smf.mnlogit(formula, data=df_ordinal)
```

```
File ~/local/lib/python3.12/site-packages/pandas/core/frame.py:4108,  
in DataFrame.__getitem__(self, key)  
    4106     if is_iterator(key):  
    4107         key = list(key)  
-> 4108     indexer = self.columns._get_indexer_strict(key, "columns")  
[1]  
    4110 # take() does not accept boolean indexers  
    4111 if getattr(indexer, "dtype", None) == bool:
```

```
File  
~/local/lib/python3.12/site-packages/pandas/core/indexes/base.py:6200  
, in Index._get_indexer_strict(self, key, axis_name)  
    6197 else:  
    6198     keyarr, indexer, new_indexer =  
self._reindex_non_unique(keyarr)  
-> 6200 self._raise_if_missing(keyarr, indexer, axis_name)  
    6202 keyarr = self.take(indexer)  
    6203 if isinstance(key, Index):  
    6204     # GH 42790 - Preserve name from an Index
```

```
File  
~/local/lib/python3.12/site-packages/pandas/core/indexes/base.py:6252  
, in Index._raise_if_missing(self, key, indexer, axis_name)  
    6249     raise KeyError(f"None of [{key}] are in the  
[{axis_name}]")  
    6251 not_found = list(ensure_index(key)[missing_mask.nonzero()  
[0]].unique())  
-> 6252 raise KeyError(f"{not_found} not in index")
```

```
KeyError: "['Adult Mortality', 'Income composition of resources'] not  
in index"
```

```
# Update the interaction features list to match the cleaned column names
```

```
interaction_features = [  
    'Adult_Mortality',  
    'Schooling',  
    'Income_composition_of_resources',  
    'BMI',  
    'Mortality_Schooling_Interaction',  
    'Mortality_Income_Interaction',  
    'Schooling_BMI_Interaction'  
]
```

```
# Update the formula and data for statsmodels ordinal logistic regression
```

```
formula = 'Life_Expectancy_Multiclass ~ ' + ' + '  
'.'.join(interaction_features)  
df_ordinal = data[['Life_Expectancy_Multiclass'] +  
interaction_features]
```

```
# Fit the ordinal logistic regression model
```

```
ordinal_model = smf.mnlogit(formula, data=df_ordinal)  
ordinal_fit = ordinal_model.fit(method='newton', maxiter=100)
```

```
# Summary of the model fit
```

```
ordinal_summary = ordinal_fit.summary()
```

```
ordinal_summary
```

```
-----  
-----
```

```
ValueError                                Traceback (most recent call  
last)
```

```
Cell In[20], line 17
```

```
    14 df_ordinal = data[['Life_Expectancy_Multiclass'] +  
interaction_features]  
    16 # Fit the ordinal logistic regression model  
--> 17 ordinal_model = smf.mnlogit(formula, data=df_ordinal)  
    18 ordinal_fit = ordinal_model.fit(method='newton', maxiter=100)  
    20 # Summary of the model fit
```

```
File
```

```
~/local/lib/python3.12/site-packages/statsmodels/base/model.py:209,  
in Model.from_formula(cls, formula, data, subset, drop_cols, *args,  
**kwargs)
```

```
    206 max_endog = cls._formula_max_endog  
    207 if (max_endog is not None and  
    208     endog.ndim > 1 and endog.shape[1] > max_endog):  
--> 209     raise ValueError('endog has evaluated to an array with  
multiple '  
    210                     'columns that has shape {}'. This occurs
```



```

-1423.7
converged: True LL-Null:
-3057.4
Covariance Type: nonrobust LLR p-value:
0.000
=====
=====
Life_Expectancy_Multiclass=1      coef      std err      z
P>|z|      [0.025      0.975]
-----
Intercept                        -8.7363      0.819      -10.672
0.000      -10.341      -7.132
Adult_Mortality                   5.1247      1.874      2.735
0.006      1.453      8.797
Schooling                       15.0423      1.873      8.031
0.000      11.371      18.714
Income_composition_of_resources   5.1185      1.066      4.800
0.000      3.028      7.209
BMI                              9.8707      1.673      5.899
0.000      6.591      13.150
Mortality_Schooling_Interaction  -11.3755      5.294      -2.149
0.032     -21.751      -1.000
Mortality_Income_Interaction     -14.8828      3.824      -3.892
0.000     -22.378      -7.387
Schooling_BMI_Interaction        -9.6064      3.164      -3.036
0.002     -15.809      -3.404
-----
Life_Expectancy_Multiclass=2      coef      std err      z
P>|z|      [0.025      0.975]
-----
Intercept                       -24.7225      1.918      -12.888
0.000     -28.482     -20.963
Adult_Mortality                  23.9474      4.046      5.919
0.000      16.017      31.878
Schooling                       16.4481      3.726      4.414
0.000      9.145      23.751
Income_composition_of_resources  25.3822      2.122     11.961
0.000      21.223      29.541
BMI                              11.2563      3.093      3.639
0.000      5.194      17.319
Mortality_Schooling_Interaction   9.4125     14.766      0.637
0.524     -19.529      38.354
Mortality_Income_Interaction     -69.7118      9.977      -6.987
0.000     -89.266     -50.158
Schooling_BMI_Interaction        -11.9307      5.030      -2.372
0.018     -21.790      -2.071

```


Resultados da Regressão Logística Ordinal

Desempenho do Modelo

- **Pseudo R²:** 0,534 – Indica que 53,4% da variância nas categorias de expectativa de vida é explicada pelos preditores.
- **Log-Likelihood:** -1423,7 – Sugere um bom ajuste do modelo em relação ao log-likelihood nulo (-3057,4).

Principais Resultados

Influências Positivas

- **Escolaridade:** Coeficiente de 15,04 – Aumenta significativamente a probabilidade de pertencer a uma categoria mais alta de expectativa de vida.
- **Composição de Renda:** Coeficiente de 5,12 – Também melhora a probabilidade de classificação em categorias superiores.
- **IMC:** Coeficiente de 9,87 – Impacta positivamente, embora menos expressivo que escolaridade.

Interações Negativas

- **Mortalidade × Escolaridade:** Coeficiente de -11,38 – Altas taxas de mortalidade reduzem o impacto positivo da escolaridade na expectativa de vida.
- **Mortalidade × Composição de Renda:** Coeficiente de -14,88 – A mortalidade também atenua os benefícios da composição de renda.

Significância

- A maioria dos coeficientes são estatisticamente significativos (**p < 0,05**), confirmando a relevância dos preditores e suas interações na determinação das categorias de expectativa de vida.

Comparações entre Categorias

- Coeficientes separados para transições entre **Baixa ↔ Média** e **Média ↔ Alta** evidenciam diferenças nos fatores que influenciam cada uma das mudanças de categoria.

```
# Visualization of predicted probabilities for each class
# Compute probabilities for each class
predicted_probs =
ordinal_fit.predict(df_ordinal[interaction_features])

# Create a DataFrame for visualization
```

```

probabilities_df = pd.DataFrame(predicted_probs, columns=['Low',
'Medium', 'High'])
probabilities_df['True Class'] = data['Life_Expectancy_Multiclass']

# Plot predicted probabilities for each true class
plt.figure(figsize=(12, 6))
for i, category in enumerate(['Low', 'Medium', 'High']):
    sns.kdeplot(probabilities_df[probabilities_df['True Class'] == i]
[category],
                label=f'{category} Class Probability',
                fill=True, alpha=0.5)

plt.title('Predicted Probabilities by True Class')
plt.xlabel('Predicted Probability')
plt.ylabel('Density')
plt.legend()
plt.show()


# Visualizing class probabilities across a subset of data
subset = probabilities_df.sample(50, random_state=42).reset_index()
plt.figure(figsize=(12, 6))
for category in ['Low', 'Medium', 'High']:
    plt.plot(subset.index, subset[category], label=f'{category}
Probability', marker='o')

plt.title('Predicted Probabilities for a Subset of Observations')
plt.xlabel('Observation Index')
plt.ylabel('Predicted Probability')
plt.legend()
plt.show()

/tmp/ipykernel_259481/1665870884.py:12: UserWarning: Dataset has 0
variance; skipping density estimate. Pass `warn_singular=False` to
disable this warning.
    sns.kdeplot(probabilities_df[probabilities_df['True Class'] == i]
[category],
/tmp/ipykernel_259481/1665870884.py:12: UserWarning: Dataset has 0
variance; skipping density estimate. Pass `warn_singular=False` to
disable this warning.
    sns.kdeplot(probabilities_df[probabilities_df['True Class'] == i]
[category],
/tmp/ipykernel_259481/1665870884.py:12: UserWarning: Dataset has 0
variance; skipping density estimate. Pass `warn_singular=False` to
disable this warning.
    sns.kdeplot(probabilities_df[probabilities_df['True Class'] == i]
[category],
/tmp/ipykernel_259481/1665870884.py:19: UserWarning: No artists with
labels found to put in legend. Note that artists whose label start
with an underscore are ignored when legend() is called with no

```

```
argument.  
plt.legend()
```



Acima, o ChatGPT gerou dois gráficos vazios.

```
# Passo: Comparar o desempenho de todos os modelos  
comparison_results = {
```

```

    "Model": [
        "Simple Linear Regression",
        "Multiple Linear Regression",
        "Polynomial Regression",
        "Ridge Regression",
        "Lasso Regression",
        "Binary Logistic Regression",
        "Multinomial Logistic Regression",
        "Ordinal Logistic Regression"
    ],
    "R² / Accuracy": [
        simple_linear_results["R²"],           # Simple
        multiple_linear_results["R²"],         # Multiple
        polynomial_results["R²"],              # Polynomial
        regularization_results["Ridge Regression"]["R²"],
        regularization_results["Lasso Regression"]["R²"],
        binary_logistic_results["Accuracy"],   # Binary
        0.80,                                  # Multinomial
        0.534,                                  # Ordinal
    ],
    "RMSE": [
        simple_linear_results["RMSE"],         # Simple
        multiple_linear_results["RMSE"],       # Multiple
        polynomial_results["RMSE"],            # Polynomial
        regularization_results["Ridge Regression"]["RMSE"],
        regularization_results["Lasso Regression"]["RMSE"],
        None,                                  # Binary
        None,                                  # Multinomial
        None,                                  # Ordinal
    ],
}

# Converte em DataFrame para melhor visualização
comparison_df = pd.DataFrame(comparison_results)

# Exibe o DataFrame (basta usar print ou display dependendo do ambiente)
print("==== Model Comparisons =====")
print(comparison_df)

```

```
comparison_df
```

```
===== Model Comparisons =====
```

	Model	R ² / Accuracy	RMSE
0	Simple Linear Regression	0.446624	0.131410
1	Multiple Linear Regression	0.724238	0.092765
2	Polynomial Regression	0.830782	0.072668
3	Ridge Regression	0.822471	0.074431
4	Lasso Regression	0.633173	0.106991
5	Binary Logistic Regression	0.882653	NaN
6	Multinomial Logistic Regression	0.800000	NaN
7	Ordinal Logistic Regression	0.534000	NaN

	Model	R ² / Accuracy	RMSE
0	Simple Linear Regression	0.446624	0.131410
1	Multiple Linear Regression	0.724238	0.092765
2	Polynomial Regression	0.830782	0.072668
3	Ridge Regression	0.822471	0.074431
4	Lasso Regression	0.633173	0.106991
5	Binary Logistic Regression	0.882653	NaN
6	Multinomial Logistic Regression	0.800000	NaN
7	Ordinal Logistic Regression	0.534000	NaN

Comparação de Métricas de Desempenho dos Modelos

Modelo	R ² / Acurácia	RM SE	Destaques
Regressão Linear Simples	0,447	0,131	Modelo básico com desempenho limitado, explicando 44,7% da variância na expectativa de vida.
Regressão Linear Múltipla	0,724	0,093	A inclusão de múltiplos preditores melhorou significativamente o desempenho.
Regressão Polinomial	0,830	0,073	Melhor desempenho entre os modelos lineares, com o maior R ² e menor RMSE.
Regressão Ridge (L2)	0,822	0,074	Regularização eficaz, mantendo quase todos os preditores sem perda significativa de precisão.
Regressão Lasso (L1)	0,633	0,107	Modelo simplificado, mas com queda na precisão devido à eliminação de muitas variáveis.
Regressão Logística Binária	88,27% (Acurácia)	N/A	Melhor modelo para classificação binária, com alta acurácia e excelente AUC (0,936).
Regressão Logística Multinomial	80% (Acurácia)	N/A	Bom desempenho em classificação de três categorias, com F1-score médio de 80%.

Modelo	R ² / Acurácia	RM SE	Destaques
Regressão Logística Ordinal	Pseudo R ² : 0,534	N/A	Explica bem a variância de categorias ordenadas, destacando interações significativas.

Destaques

- **Regressão Polinomial:** Melhor desempenho para modelagem linear, com o maior R² (0,83) e menor RMSE (0,073).
- **Regressão Logística Binária:** Maior acurácia (88,27%) em tarefas de classificação binária.
- **Regressão Logística Ordinal:** Explica bem a variância de categorias ordenadas com Pseudo R² de 0,534, sendo ideal para dados categóricos ordenados.

A tabela permite uma visão clara da eficácia de cada abordagem para diferentes tipos de problemas.

Interpretação dos Resultados

1. Modelos Lineares (Regressão Linear Simples, Múltipla e Polinomial)

Regressão Linear Simples

- R²: 0,447 | RMSE: 0,131.
- Utilizando apenas um preditor (Mortalidade Adulta), o modelo explica 44,7% da variância na expectativa de vida.
- Embora simples, serve como ponto de partida, mas é limitado pela falta de complexidade.

Regressão Linear Múltipla

- R²: 0,724 | RMSE: 0,093.
- A adição de múltiplos preditores (ex.: Escolaridade, IMC) melhorou significativamente o desempenho do modelo.
- Isso destaca que a expectativa de vida é influenciada por diversos fatores além da mortalidade.

Regressão Polinomial

- R²: 0,831 | RMSE: 0,073.
- Alcançou o melhor desempenho, capturando relações não lineares e interações entre os preditores.
- Apesar de sua eficácia, a maior complexidade aumenta o risco de overfitting, caso não seja validada adequadamente.

2. Modelos Regularizados (Ridge e Lasso Regression)

Regressão Ridge

- **R²:** 0,822 | **RMSE:** 0,074.
- Retém todas as variáveis e penaliza coeficientes grandes para evitar overfitting.
- Desempenho comparável à regressão polinomial, mas com melhor generalização devido à regularização.

Regressão Lasso

- **R²:** 0,633 | **RMSE:** 0,107.
 - Reduz agressivamente os coeficientes, mantendo apenas os preditores mais importantes.
 - Útil para seleção de variáveis, mas neste caso, sacrificou a precisão.
-

3. Modelos de Classificação (Regressão Logística Binária e Multinomial)

Regressão Logística Binária

- **Acurácia:** 88,27% | **ROC AUC:** 0,936.
- Separa de forma eficaz os grupos de alta e baixa expectativa de vida.
- Alto poder discriminatório, evidenciado pelo elevado valor de AUC.

Regressão Logística Multinomial

- **Acurácia:** 80%.
 - Desempenho sólido na previsão de categorias "Baixa," "Média" e "Alta" de expectativa de vida.
 - A maioria dos erros ocorre entre categorias adjacentes, o que é esperado em desfechos ordenados.
-

4. Regressão Logística Ordinal

- **Pseudo R²:** 0,534.
 - Explica 53,4% da variância em categorias ordenadas de expectativa de vida.
 - Captura a natureza ordinal do alvo, fornecendo insights mais profundos sobre as transições entre categorias.
 - **Coefficientes Relevantes:**
 - **Escolaridade** e **Composição de Renda** têm fortes efeitos positivos.
 - Interações como **Mortalidade × Escolaridade** destacam dinâmicas complexas, como o efeito mitigador da educação sobre a mortalidade.
-

Principais Conclusões

Para Tarefas de Predição

- **Regressão Polinomial:** Melhor escolha para previsão contínua de expectativa de vida, com o maior R^2 (0,831) e menor **RMSE** (0,073).
- **Regressão Ridge:** Alternativa mais simples e generalizável, com desempenho comparável.

Para Tarefas de Classificação

- **Regressão Logística Binária:** Ideal para distinguir grupos de alta e baixa expectativa de vida, com alta acurácia (88,27%) e AUC (0,936).
- **Regressão Logística Multinomial:** Funciona bem para problemas de múltiplas classes, mas a **Regressão Logística Ordinal** é mais interpretável para desfechos ordenados.

Insights sobre os Preditores

- **Escolaridade** e **Composição de Renda** são os preditores mais influentes, contribuindo consistentemente de forma positiva.
- **Termos de Interação:** Relações como **Mortalidade × Escolaridade** mostram efeitos sutis, como o papel mitigador da educação sobre a mortalidade.

Esses resultados fornecem uma base sólida para decisões baseadas em dados, seja para predição ou para classificação de expectativas de vida.

4. Evaluation

Relatório de Avaliação: Análise e Insights

1. Análise dos Resultados

Insights e Padrões Identificados

Relações Preditivas

- **Escolaridade** e **Composição de Renda** possuem fortes correlações com a expectativa de vida, destacando a importância da educação e dos recursos econômicos para melhorar os resultados de saúde pública.
- **Mortalidade Adulta** impacta negativamente a expectativa de vida, enfatizando a necessidade de iniciativas de saúde para reduzir a mortalidade.
- **Termos de interação revelaram relações complexas:**
 - **Mortalidade × Escolaridade:** Níveis mais altos de educação reduzem o impacto negativo das taxas de mortalidade na expectativa de vida.
 - **Mortalidade × Composição de Renda:** Recursos econômicos elevados mitigam os efeitos de alta mortalidade.

Tendências

- Países com maior **PIB per capita** e **gastos com saúde** apresentaram melhores resultados de expectativa de vida, alinhando-se aos objetivos de equidade global em saúde.
- **Disparidades entre países em desenvolvimento e desenvolvidos** foram evidentes, com nações desenvolvidas alcançando consistentemente métricas mais altas de expectativa de vida.

Relevância para Questões de Negócio/Pesquisa

- **Alinhamento com os Objetivos:** O projeto identificou com eficácia os principais fatores que influenciam a expectativa de vida e avaliou seu impacto relativo, respondendo diretamente à questão de melhorar a saúde pública.
 - **Recomendações de Políticas:** Os insights apoiam iniciativas políticas focadas em educação, igualdade de renda e acesso à saúde, especialmente em países em desenvolvimento.
 - **Evidência Quantitativa:**
 - Valores de **R²** (ex.: Regressão Polinomial: 0,83) mostram que os preditores explicam uma proporção significativa da variância na expectativa de vida.
 - Modelos de classificação alcançaram alta precisão (ex.: Regressão Logística Binária: 88,27%), confirmando a confiabilidade das previsões.
-

2. Avaliação dos Algoritmos

Avaliação de Desempenho

Modelos de Regressão

- **Regressão Polinomial:**
 - Melhor desempenho (**R²: 0,83, RMSE: 0,073**) para previsão contínua de expectativa de vida.
 - **Força:** Captura relações não lineares e interações.
 - **Fraqueza:** Complexidade elevada aumenta o risco de overfitting.
- **Regressão Ridge:**
 - Desempenho equilibrado (**R²: 0,82, RMSE: 0,074**) com melhor generalização devido à regularização L2.
 - Ideal para cenários que exigem previsões robustas com risco mínimo de overfitting.
- **Regressão Lasso:**
 - Modelo simplificado com menos preditores, mas desempenho inferior (**R²: 0,63, RMSE: 0,107**), sendo menos adequado para este conjunto de dados.

Modelos de Classificação

- **Regressão Logística Binária:**
 - Melhor acurácia (**88,27%**) e excelente **ROC AUC (0,936)**.
 - **Força:** Forte poder discriminatório para resultados binários.
- **Regressão Logística Multinomial:**

- Acurácia razoável (**80%**) para classificação de múltiplas categorias.
- **Fraqueza:** Erros de classificação ocorreram principalmente entre categorias adjacentes (ex.: Baixa ↔ Média expectativa de vida).
- **Regressão Logística Ordinal:**
 - **Pseudo R²:** 0,534 – Explica bem desfechos ordenados.
 - Oferece insights profundos sobre transições entre categorias, sendo ideal para variáveis categóricas ordenadas.

Complexidade Computacional e Tempo de Execução

- A maioria dos modelos foi executada de forma eficiente, incluindo os mais complexos, como Regressão Polinomial e Logística Ordinal.
- Técnicas de regularização (Ridge, Lasso) demonstraram eficiência no controle de overfitting.

Forças e Fraquezas

- **Forças:**
 - Regressão Polinomial capturou relações complexas de forma eficaz.
 - Regressão Ridge equilibrou desempenho e simplicidade.
 - Modelos de Regressão Logística proporcionaram classificações robustas com alta interpretabilidade.
 - **Fraquezas:**
 - A alta complexidade da Regressão Polinomial requer validação cuidadosa.
 - Regressão Lasso sacrificou desempenho pela simplicidade, o que foi menos benéfico neste caso.
-

3. Considerações Finais

Desafios e Soluções

- **Limpeza de Dados:**
 - **Desafio:** Valores ausentes em colunas críticas (ex.: Hepatite B, PIB).
 - **Solução:** Imputação com valores medianos e tratamento cuidadoso de dados categóricos.
- **Engenharia de Recursos:**
 - **Desafio:** Identificar termos de interação significativos.
 - **Solução:** Construção manual de interações com base em conhecimento de domínio.
- **Seleção de Modelos:**
 - **Desafio:** Balancear precisão e interpretabilidade.
 - **Solução:** Avaliação de modelos simples e complexos para atender às diversas necessidades das partes interessadas.

O Que Funcionou Bem

- Rigor metodológico ao testar múltiplos modelos proporcionou insights abrangentes.

- Etapas de preparação dos dados, como escalonamento e codificação, melhoraram o desempenho dos modelos.
- Análises estatísticas (ex.: valores de p , R^2) validaram a confiabilidade dos preditores.

Sugestões para Melhoria

- **Dados Adicionais:**
 - Incluir mais indicadores socioeconômicos (ex.: índices de acesso à saúde, taxas de alfabetização) pode melhorar as previsões.
 - Explorar tendências temporais ou efeitos defasados usando dados longitudinais.
- **Modelos Refinados:**
 - Implementar métodos de ensemble (ex.: Random Forest, Gradient Boosting) pode aumentar ainda mais a precisão.
 - Uso de validação cruzada para garantir melhor generalização em modelos complexos.
- **Considerações Éticas:**
 - Avaliar possíveis vieses na coleta de dados, especialmente em países em desenvolvimento, garantiria insights mais justos.

Principais Lições Aprendidas

- Modelos mais simples, como a Regressão Ridge, muitas vezes oferecem desempenho comparável a modelos mais complexos, com melhor generalização.
 - O tratamento adequado de variáveis categóricas e ordinais é crucial para tarefas de classificação.
-

Resumo

- **Melhor Modelo para Predição:** Regressão Polinomial (R^2 : 0,83, RMSE: 0,073).
- **Melhor Modelo para Classificação:** Regressão Logística Binária (Acurácia: 88,27%, AUC: 0,936).
- **Insights de Negócio:** Educação e recursos econômicos são os principais fatores que impulsionam a expectativa de vida, com grande potencial para intervenções direcionadas.
- **Próximos Passos:** Refinar modelos com dados adicionais e avaliar técnicas de ensemble para melhorias futuras.